Mendelova univerzita v Brně
Provozně ekonomická fakulta

Binární klasifikace zákaznických incidentů pomocí metod NLP

Bakalářská práce

Vedoucí práce:
doc. Ing. František Dařena, Ph.D.

Jiří Pokorný

Brno 2023

NA TOMTO LISTU SE NACHÁZÍ ORIGINÁLNÍ ZADÁNÍ PRÁCE

Poděkování

Chtěl bych poděkovat doc. Ing. Františku Dařenovi, Ph.D. za odborné vedení, trpělivost a cenné rady při tvorbě této práce.

Čestné prohlášení

Prohlašuji, že jsem práci **Binární klasifikace zákaznických incidentů pomocí metod NLP** vypracoval samostatně a veškeré použité prameny a informace uvádím v seznamu použité literatury. Souhlasím, aby moje práce byla zveřejněna v souladu s § 47b zákona č. 111/1998 Sb., o vysokých školách ve znění pozdějších předpisů a v souladu s platnou Směrnicí o zveřejňování závěrečných prací.

Jsem si vědom, že se na moji práci vztahuje zákon č. 121/2000 Sb., autorský zákon, a že Mendelova univerzita v Brně má právo na uzavření licenční smlouvy a užití této práce jako školního díla podle § 60 odst. 1 autorského zákona.

Dále se zavazuji, že před sepsáním licenční smlouvy o využití díla jinou osobou (subjektem) si vyžádám písemné stanovisko univerzity, že předmětná licenční smlouva není v rozporu s oprávněnými zájmy univerzity, a zavazuji se uhradit případný příspěvek na úhradu nákladů spojených se vznikem díla, a to až do jejich skutečné výše.

V Brně dne 29. dubna 2023 .....

podpis

Abstract

Pokorný, Jiří. Binary classification of customer incidents using NLP methods. Brno: Mendel University in Brno, 2023.

This bachelor thesis focuses on building a model for binary classification of customer incidents within the SAP system. By classifying the individual sentences of incidents, the final category of the incident is predicted. The used text is in English. To compare traditional and modern approaches to text classification as well as obtain optimal results, a series of experiments is carried out using different methods of balancing the dataset, vector representation and classification. Finally, the results are analyzed and recommendation is formulated with regard to further development, including applying knowledge gained within the SAP environment.

Key words: NLP, text classification, customer incidents, TF-IDF, Word2vec, Doc2vec, DistilBERT

Abstrakt

Pokorný, Jiří. Binární klasifikace zákaznických incidentů pomocí metod NLP. Brno: Mendelova Univerzita v Brně, 2023.

Tato bakalářská práce se zabývá vybudováním modelu umožňujícího binární klasifikaci zákaznických incidentů v rámci systému SAP. Klasifikace je provedena pro věty obsažené v incidentech, dle čehož je určena konečná kategorie incidentu. Využitý text je v anglickém jazyce. Za účelem porovnání tradičních a moderních přístupů pro textovou klasifikaci, a získání optimálního výsledku, je provedena série experimentů obnášející využití různých metod vyvážení datasetu, vektorové reprezentace a klasifikačních algoritmů. Výsledky jsou v konečné řadě zhodnoceny a je zformulováno doporučení s ohledem na další rozvoj, včetně uplatnění získaných znalostí v prostředí SAP.

Klíčová slova: NLP, textová klasifikace, zákaznické incidenty, TF-IDF, Word2vec, Doc2vec, DistilBERT

Obsah

1 Úvod **14**

2 Cíl **15**

3 Současný stav problematiky **16**
3.1 SAP S/4HANA . . . 16
3.1.1 Migrace . . . 17
3.1.2 Zvýšení verze . . . 17
3.2 SAP Support . . . 18
3.3 Strojové učení . . . 19
3.4 Zpracování přirozeného jazyka . . . 19
3.4.1 Textová klasifikace . . . 20
3.5 Předzpracování . . . 20
3.6 Reprezentace textu . . . 22
3.6.1 TF-IDF . . . 23
3.6.2 Word2vec . . . 24
3.6.3 Doc2vec . . . 25
3.7 Klasifikátory . . . 26
3.8 Transformery . . . 27
3.8.1 DistilBERT . . . 28
3.9 Evaluace . . . 29
3.10 Existující řešení . . . 31

4 Metodika **34**
4.1 Použité prostředky . . . 34
4.2 Data . . . 34
4.3 Experimenty . . . 37
4.3.1 Předzpracování dat . . . 37
4.3.2 Vyvážení dat . . . 38
4.3.3 Rozdělení dat . . . 39
4.3.4 Reprezentace textu . . . 39
4.3.5 Klasifikátory . . . 39
4.3.6 Evaluace . . . 40

5 Výsledky **41**
5.1 Využitý text . . . 41
5.2 Vyvážení dat . . . 42
5.3 Vektorové reprezentace . . . 43
5.4 Stabilita výsledků . . . 44

6 Diskuze **45**

7 Závěr **47**

8 Literatura **48**

Přílohy **52**

A SAP incident **53**

B Hyperparametry modelů **54**
B.1 Doc2vec - odstranění šumu 54
B.2 Doc2vec - klasifikace 54
B.3 Word2Vec 54
B.4 DistilBERT 55
B.5 TF-IDF 55

C Elektronická příloha **56**

Seznam obrázků

Obrázek 1: Architektura distilBERT, její komponenty a porovnání s BERT *Zdroj:* (Adel , 2022) 29
Obrázek 2: Přehled zkoumaných možností v rámci jednotlivých kroků experimentů 37
Obrázek 3: Stabilita výsledků F1 skóre v závislosti na počtu vět pro nejlepší TF-IDF experiment 44

Seznam tabulek

Tabulka 1: Přehled množství datových vzorků pro učení modelu 38
Tabulka 2: Nejlepší výsledky klasifikace dle metriky F1 při a bez zahrnutí vět z komunikační části 41
Tabulka 3: Nejlepší výsledky klasifikace dle F1 skóre na základě využité metody vyvážení dat 42
Tabulka 4: Nejlepší výsledky klasifikace dle recall skóre na základě využité metody vyvážení dat 42
Tabulka 5: Nejlepší výsledky klasifikace dle metriky F1 na základě reprezentace dat 43
Tabulka 6: Matice záměn pro nejlepší klasifikátor dle metriky F1 skóre 43
Tabulka 7: Nejlepší výsledky klasifikace dle metriky recall na základě reprezentace dat 43
Tabulka 8: Matice záměn pro nejlepší klasifikátor dle metriky recall skóre - DistilBERT 44

1 Úvod

Zpracování přirozeného jazyka (NLP) označuje oblast umělé inteligence, jejíž cílem je umožnit strojům pochopení a zpracování lidského jazyka. V nedávné době se aplikace NLP rozšířila z laboratoří a univerzit do různých oblastí jako velkoobchod, zdravotnictví, finance, právo, marketing a dalších (Vajalla et al., 2020).

NLP proniklo i do IT firem, kde se začaly uplatňovat např. pro klasifikaci incidentů, jež jsou u těchto firem vytvářeny a zprostředkovávány skrze tzv. „service desk“. Incidenty jsou vytvářeny zákazníky v případě, že mají vůči společnosti požadavek či potřebují podporu při řešení nějakého problému spjatého s využíváním produktu firmy. Klasifikační systém na základě textu popisující problém incidentu umožňuje daný tiket automaticky přiřadit do jedné z předem stanovených kategorií. To poskytuje velmi výhodnou alternativu pro tradiční přístup, kdy je kategorie incidentu stanovena zaměstnanci firmy, což je mnohdy drahý a neefektivní proces. Klasifikační systémy mnohdy dosahují lepších výsledků, než v případě manuální klasifikace. Současně je toto množství vytvořených incidentů v rámci IT firem neustále vyšší, zejména díky snahám o co nejvyšší digitalizaci napříč celým sektorem. IT firmy proto čelí čím dál vyššímu tlaku automatizovat jejich service desky, za účelem zvýšení spokojenosti zákazníků a snížení nákladů (Fuchs et al., 2022).

Tato práce se bude zaměřovat na vybudování takového klasifikačního systému incidentů souvisejících s migrací a upgrade, a to v rámci spolupráce s firmou SAP. Půjde o rozšíření pro současně budovaný klasifikační systém, který filtruje relevantní věty incidentů. Systém v rámci této práce dále tyto věty binárně klasifikuje dle toho, zda se týkají migrace či upgrade. Dle určené konečné kategorie vět je poté určena finální kategorie incidentů. V případě, že incident obsahuje alespoň jednu větu spjatou s upgrade, bude celý incident klasifikován jako upgrade.

Klasifikátor poté bude využit v rámci rozsáhlejšího systému vybudovaným nad rámec této práce. Po nasazení tento rozsáhlejší systém uživateli na základě určené kategorie incidentu nabídne řadu dříve identifikovaných možných řešení. V optimálním případě lze následně očekávat redukci vytvořených tiketů, a tedy i dosažení zmiňovaných výhod klasifikačních systémů. Veškeré získané poznatky při budování klasifikátorů lze také uplatnit pro vytváření dalších klasifikačních systémů v rámci společnosti SAP a jako příručka pro osoby, které začínají s vývojem NLP aplikací.

2 Cíl

Cílem této práce je návrh a implementace modelu pro binární klasifikaci zákaznických incidentů v rámci systému SAP, přičemž systém má predikovat nový incident jako relevantní v případě, že se týká přechodu na vyšší verzi systému S/4HANA společnosti SAP, a nerelevantní či nikoliv.

Sérií experimentů, které budou zahrnovat využití různých způsobů vyvážení dat, vektorové reprezentace dat a klasifikačních algoritmů, bude identifikována taková kombinace, která dosáhne nejlepších výsledků pro klasifikaci vět spojených se zvýšením verze systému S/4HANA. Práce bude taktéž zahrnovat získání dat, přípravu dat pro učení, předzpracování s využitím NLP, evaluaci, analýzu a vyhodnocení.

3 Současný stav problematiky

Následující sekce se zaměřují na teoretický přehled znalostí, které je třeba prozkoumat, aby bylo možné pochopit další kapitoly práce a východiska pro bakalářskou práci.

Vzhledem k tomu, že tato práce bude vytvořena v rámci úzké spolupráce s firmou SAP, a v souvislosti s jejím klíčovým produktem S/4HANA, budou v první řadě představeny klíčové aspekty této firmy a jejího software. Poté bude předložena obecná teorie z oblasti strojového učení, zpracování přirozeného jazyka (NLP) a textové klasifikace. Následuje popis jednotlivých fází procesu textové klasifikace včetně možností vektorové reprezentace textu a klasifikačních algoritmů. Dále budou popsány transfomery, a to zejména DistilBERT, jež následují díky tomu, že kombinují schopnosti jak vektorizace, tak i klasifikace. V poslední řadě budou prozkoumány již existující práce zabývající se textovou klasifikací pro obdobné problémy jako ten, jež je řešen v rámci tohoto řešení.

3.1 SAP S/4HANA

SAP S/4HANA je aplikace vyvinutá firmou SAP a označována jako enterprise resource planning (ERP) software.

Obecně je uplatnění ERP softwaru rozličné a přináší pro organizace napříč všemi sektory řadu výhod. Využívá se k řízení každodenních aktivit podniku jako účetnictví, řízení dodávek, projektů, rizik či operací dodavatelského řetězce. ERP zahrnuje taktéž software pro plánování, vytváření rozpočtů, predikci a vykazování obchodních výsledků. Mezi výhody ERP software patří dle SAP (2023) vyšší produktivita, vyšší míra automatizace procesů, hlubší porozumění podniku, rychlejší vykazování činností, snížení rizika vzniku problémů, zjednoduššení IT služeb či zlepšení schopnosti reagovat na nové příležitosti.

Firma SAP má ve vývoji ERP produktů dlouholetou historii a tvoří jádro jejího portfolia. Prvním produktem se pro ni stal v roce 1979 již SAP R/2, následován SAP R/3 v roce 1992 a v roce 2006, s boomem internetu, byl vydán i SAP ERP 6.0 (Baumgartl et al., 2016). V roce 2015 přišel na trh také již zmiňovaný SAP S/4HANA, v cloudové verzi S/4HANA Cloud a S/4HANA On-Premise, kdy obě varianty mají oproti starším verzím ERP od SAP širokou škálu inovací a výhod.

Obě verze S/4HANA například následují trendy digitální transformace jako využití sociálních medií, big data či IoT. SAP taktéž u tohoto produktu aplikuje tzv. princip „ONE“. Tento princip vytváří strategii, jejíž snahou je odstranit co nejvíce přebytečných frameworků, technologií a datových modelů. což se taktéž značně projevuje na zvýšené rychlosti vykonání operací u nového produktu. (Baumgartl et al., 2016). Tento produkt lze také poprvé u SAP produktů využívat na jakémkoliv zařízení a poskytuje značnou úroveň přizpůsobení frontendu aplikace, dle toho, jakou roli má uživatel v dané organizaci.

Tyto změny objasňují, proč se podniky mohou rozhodnout pro implementaci S4/HANA (ať už Cloud či On-Premise verze) do svého firemního prostředí.

3.1.1 Migrace

V předchozí kapitole byly zmíněny historické ERP produkty společnosti SAP a taktéž řada výhod nejnovějšího ERP produktu S/4HANA.

Ze zmíněných produktů předcházející S/4HANA je v současnosti vývojovými týmy SAPU podporován pouze produkt SAP ERP 6.0. Dle současné strategie SAP je ovšem podpora tohoto produktu v tuto chvíli garantována do konce roku 2025. V případě, že zákazník využívá nejnovější enhancement package spjatý s tímto software, mají možnost jej s prodlouženou a placenou podporou využívat až do roku 2030 (Schmidthals, 2022).

Z tohoto důvodu, i čistě z motivace používat nové funkce obsažené v S/4HANA, je v rámci SAP v současnosti velmi frekventovaným scénářem migrace zákazníků ze starších SAP ERP systémů na systém S/4HANA. Takový proces se označuje jako „brownfield“ konverze a týká se pouze verze S/4HANA On-premise, jelikož u cloudové verze nelze takovou konverzi provést.

Pro migraci/konverzi na tento software je nutná značně dlouhá příprava a i s přípravou se stále jedná o komplikovaný proces. Vzhledem k využití zcela jiné architektury a datového modelu oproti dřívejším ERP systémům společnosti SAP je vyžadováno rozsáhlé čištění a úprava dat, než jsou převedeny na nový cílový systém. SAP proto pro zjednodušení tohoto procesu vytvořil velmi detailní postup a množství nástrojů, které zákazníkům mohou proces zjednodušit.

I přesto je však s migrací velmi často spjat výskyt mnoha chyb a zábran, které proces zpomalují. V případě velkých multinárodních společností může takové zpomalení vést k obrovským finančním ztrátám. Z pohledu SAP se na druhou stranu zákazníci kvůli těmto chybám obrací na zákaznickou podporu, což stojí společnost velké množství zdrojů a času pracovníků SAP podpory.

Řešení, jež se tedy zaměřují na zjednodušení procesu migrace či na efektivnější řešení chyb, které při tomto scénáři nastávají, jsou v současnosti velmi relevantní.

3.1.2 Zvýšení verze

V předchozí sekci byl popsán scénář migrace ze starších SAP ERP systémů na systém S/4HANA. S tím souvisí i takzvaný scénář zvýšení verze (dále „upgrade“) systému S/4HANA.

SAP každoročně pro S/4HANA Cloud a On-Premise vydává novou funkcionalitu a inovace v podobě nových verzí. Pochopitelně je tedy každoročně vzrůstající počet uživatelů, využívající tento software, motivován těchto funkcionalit využít, aby maximalizovali užitek jejich ERP systému. Stejně jako u starších produktů společnosti SAP je taktéž u zastaralých verzí S/4HANA postupně rušena podpora a zákazníci proto svůj S/4HANA systém frekventovaně převádějí na vyšší verzi.

I když se nejedná o tak komplikovaný proces jako v případě migrace, je stále upgrade časově náročný scénář vyžadující mnoho zdrojů. Dle statistik SAP může upgrade na vyšší verzi S/4HANA trvat průměrně 1,5 až 4 měsíce ('SAP', 2023). Jen díky komplexnosti tohoto procesu, lze stejně jako u migrace, očekávat že zákazníci při upgrade pravděpodobně narazí na určité problémy zpomalující jejich pokrok. S tím je pro SAP i zákazníky této společnosti spjato vynaložení nadbytečných nákladů na jejich vyřešení. Řešení, jež by tyto náklady limitovalo je tedy pro SAP ve všech směrech velmi žádoucí. S přelivem zákazníků ze starších ERP systémů na S/4HANA, lze také očekávat, že v blízké budoucnosti bude toto téma ještě relevantnější než dnes.

3.2 SAP Support

Poskytování technické podpory pro vlastní IT produkty je integrální součástí firem, jež vyvíjí či zprostředkovávají software (Gupta et al., 2018). Výjimkou není ani SAP, jehož zákazníci často využívají technické podpory právě pro řešení problémů popsaných v předchozích sekcích textu.

Pro SAP a další firmy jde o kritickou podnikovou oblast, jelikož je v případě selhání riskováno zhoršení image a reputace společnosti. Ve vysoce soutěživém prostředí může jedna špatná zákaznická zkušenost odradit potenciální zákazníky a zvýšit riziko odchodu zákazníků současných (Büyüköz et al., 2020).

SAP pro poskytování technické podpory vytvořil řadu nástrojů. Těmi dvěma hlavními jsou:

- **SAP ONE Support Launchpad vyhledávání**
  Jde o robustní nástroj, který slouží pro vyhledávání napříč několika SAP repozitáři, komunitních fórech, wikipediích atd. Vyhledávání probíhá i v rámci tzv. „Notes“, jež slouží ke korekci komplexních technických problémů v rámci SAP produktů. Většina z nich obsahuje i kód a k jejich použití lze využít speciální implementační nástroj.

- **Vytvoření incidentu**
  V případě, že je předchozí zdroj pro zákazníka nedostatečný, je možné požádat SAP o technickou podporu skrze dedikovaný webový service desk. V rámci tohoto systému může zákazník, využívající SAP produkty, vytvořit incident popisující jejich problém či požadavek. Zákazník zde taktéž zadá strukturovaný text jako např. identifikaci firmy/osoby, která incident zakládá, prioritu či závažnost. Osloví tím tým expertů dané domény incidentu, kteří mu poté mohou pomoci (Opuchlich, 2019). V rámci každého incidentu je poté pro daného řešitele a zákazníka možné komunikovat. V rámci těchto zpráv jsou pokládány otázky pro upřesnění problému či je poskytnuto samotného řešení. Řešení je ve většině případů specifikováno detailním postupem či odkázáním na určitou Note či jiný externí zdroj.

Optimální situací je, pokud si zákazník vyhledá řešení sám. V takovém případě, není společností SAP vynaloženo na řešení žádných finančních nákladů. Existuje zde tedy snaha redukovat toto množství vytvořených incidentů. Na základě této snahy vznikla v rámci zákaznického oddělení SAP, zvaném „Proactive Maintenance“, i hlavní myšlenka této práce.

3.3 Strojové učení

Společnost SAP začala v posledních letech masivně investovat do zlepšování svých procesů pomocí strojového učení. Vzhledem k tomu, že tato práce taktéž do vysoké míry využívá strojového učení využívá, je nutné tento pojem objasnit (Tan, 2022).

Strojové učení lze definovat jako množinu metod, které umožňují automaticky detekovat vzory v datech a poté tyto odkryté vzory použít pro predikci výsledku na dosud neprozkoumaných datech (Murphy, 2012).

V rámci strojového učení je nutné rozlišit mezi termíny algoritmus a model. Algoritmus slouží k vytvoření modelu strojového učení, kdy tento algoritmus vyhledává v datech vzory (tedy „učí se“). Analogií pro takto vytvoření model lze považovat ve výpočetní technice program. Model je poté složen jak z dat, tak i procedury, kdy tato procedura následně data využívá pro predikci na neprozkoumaných datech (Brownlee, 2020).

Algoritmy strojového učení mohou být seskupeny do dvou hlavních kategorií:

- **Učení s učitelem**
  Při učení s učitelem je cílem naučit mapování mezi vstupy x a výstupy y, a to na základě velkého množství instancí párů obsahující jak vstup, tak i příslušný výstup. Tyto páry jsou taktéž označované jako data na učení a výstupy se poté označují jako „labely“ či také „ground truth“ (Vajalla et al., 2020). Pod učení s učitelem patří například úlohy klasifikace či regrese.
- **Učení bez učitele**
  Učení bez učitele má za cíl odhalit skryté vzory na vstupních datech, aniž by se zde využívalo labelů. Jde o kategorii strojového učení, která je mnohem šíře aplikovatelná, vzhledem k tomu, že u ní není potřeba provést často velmi drahý proces labelovaní dat (Murphy, 2012). Tato metoda mnohem lépe imituje proces učení v lidském mozku než-li učení s učitelem. Pod učení bez učitele spadá shlukování či asociace.

3.4 Zpracování přirozeného jazyka

Zpracování přirozeného jazyka, v angličtině „Natural Language Processing“ (dále „NLP“), označuje podobor umělé inteligence a lingvistiky, který se zabývá analýzou, modelováním a pochopením lidského jazyka (Vajalla et al., 2020).

Lidským jazykem rozumíme řečený či psaný projev, využívaný za účelem komunikace. Zpracování přirozeného jazyka bylo stvořeno primárně proto, aby byla

umožněna komunikace osob se stroji. A to aniž by se lidé museli učit jazyk, který využívá stroj (Choprya et al., 2004).

Každá inteligentní aplikace, jež využívá lidský jazyk používá NLP. I přesto, že ze začátku bylo NLP spíše nezávislým oborem, poslední dobou začal být vývoj této oblasti být do vysoké míry ovlivňován právě i metodami strojového učení a také metodami hlubokého učení (Vajalla et al., 2020). Mezi základní NLP úlohy patří například strojový překlad, získávání informací či textová klasifikace.

3.4.1 Textová klasifikace

Nejčastější NLP úlohou, jež využívá strojového učení, je textová klasifikace, která bude i hlavním úkolem této práce. Klasifikace může být různých druhů. U binární klasifikace se predikuje náležitost instance do jedné či druhé třídy. U multi-class klasifikace se predikuje náležitost instance do tří a více tříd. U multi-label klasifikace se u jednotlivých datových instancí predikuje příslušnost ke dvou a více kategoriím současně.

Dále Vajalla et. al (2020) definoval klíčové fáze, jež definují proces tvorby systému textové klasifikace (týkající se všech třech typů):

1. **Sběr dat** – Na začátku procesu dochází ke sběru dostatečného množství dat vhodných pro daný úkol. Může následovat také jejich labelování (tedy přiřazení datových instancí ke kategorii, k níž náleží).
2. **Předzpracování** – Čištění, transformace a organizace dat, aby je bylo možné použít pro algoritmus strojového učení.
3. **Rozdělení datasetu** – Rozdělení dat do množiny pro učení modelu a testování modelu (popř. také i validační množiny).
4. **Vytvoření vektorové reprezentace** - Konvertování předzpracovaných textových dat do numerické podoby.
5. **Učení klasifikátoru** – Učení modelu strojového učení na vytvořených vektorových reprezentacích a korespondujících labelech z množiny pro učení.
6. **Evaluace** – Využití testovací množiny dat a evaluačních metrik pro posouzení výkonu modelu.
7. **Nasazení** – Nasazení modelu do produkčního prostředí.

V následujících sekcích textu budou fáze textové klasifikace, jako předzpracování dat, vytvoření vektorové reprezentace a evaluace, dále detailněji vysvětleny.

3.5 Předzpracování

Textová data využívaná pro NLP úlohy jsou zřídkakdy v podobě, jaká je nutná pro optimální výkon algoritmů strojového učení. Předzpracování je proto jedním

z nejdůležitějších kroků v jakékoliv NLP aplikaci (Raschka, 2016).

V zásadě se při předzpracování transformuje nestrukturovaný text na text strukturovaný. Cílem je uchovat co nejvíce informací, aniž by byl negativně ovlivněn výsledek predikce modelu (Büyüköz et al., 2020).
Hlavními kroky předzpracování jsou následující:

- **Čištění**
  V mnoha případech obsahují textová data sekvence znaků jako HTML tagy, ukotvení a jiné metadata. Čištění odkazuje na proces extrahování čistého textu z těchto dat pomocí specializovaných parsovacích a extrakčních technik (Raschka, 2016).
- **Segmentace vět a tokenizace**
  Pro mnohé use case je v rámci předzpracování rozdělen text na věty. Oddělovačem jsou v tomto případě tečky, otazníky či vykřičníky, kdy je ovšem nutné brát v potaz, že tyto znaky se mohou vyskytnout i uprostřed vět (např. u zkratek). Častěji využívaným krokem je tokenizace, kdy rozdělení probíhá na úrovni slov.
- **Stematizace**
  Stematizace označuje proces redukce slov na jejich základní formu odstraněním jejich přípon a předpon. Jsou tím různé varianty jednotlivých slov, používaných s jinými předponami, v jiném čísle či skloňování, sjednoceny do jednotné formy. Stematizaci často předchází převod veškerých písmen na uppercase či lowercase (Vajalla et al., 2020). Proces stematizace pro jednotlivá slova silně závisí na jazyku textu, na jakém je stematizace aplikována. (Raschka, 2016).
- **Lematizace**
  Lematizace pracuje na obdobném principu jako stematizace. Při lematizaci se ovšem také bere v potaz kontext slov a převádí se na základní slovníkový tvar, tedy tzv. „lemmata“.
- **Odstranění stop slov**
  V textech se vyskytují s vysokou četností slova bez podstatného významu. V angličtině může jít např. o členy (a, an, the), zájmena a spojky (Büyüköz et al., 2020). Vzhledem k tomu, že mají minimální dopad na význam textu, jsou často tato slova v rámci procesu předzpracování odstraněna.

Předzpracování se typicky skládá z mnoha těchto kroků, kdy využití či pořadí těchto kroků závisí na dané NLP úloze, využitém modelu apod.. Například u transformerů, jež jsou popsané v sekci 3.8, zahrnuje typicky předzpracování pouze základní očištění. Zahrnutí jiných kroků u nich může vést ke zkreslení vytvořených vektorů a ztrátě kontextových informací. To se typicky projeví v podobě horších výsledků klasifikace transformerů.

3.6 Reprezentace textu

Po předzpracování textových dat, je vytvořena pro data tzv. „vektorová reprezentace“. Tato fáze obnáší transformaci textu do podoby číselných vektorů, které lze poté použít pro klasifikační algoritmy. Tyto vektory jsou pevné délky (Büyüköz et al., 2020).

Existuje mnoho způsobů, jak tuto transformaci textu na vektory provést. Při výběru specifického způsobu reprezentace záleží primárně na charakteru úlohy, v rámci níž jsou vektory využity a zpracovávaných datech. V případě, že nejsou vektory dostatečně informativní, výsledný model nemůže být dostatečně výkonný. Také v případě, že je numerických hodnot ve vektorech (dále tzv. „rysů“) excesivní množství, či pokud nejsou relevantní, bude učení modelu mnohem dražší a náročnější (Zheng et. al, 2018).

Vektorizační přístupy se dělí dle různých autorů odlišným způsobem, v zásadě jsou však kategorizovány zejména na základě historického vývoje v rámci těchto přístupů. Staykovski et al. (2019) dělí vektorizační techniky dle toho, zda vyprodukují husté či řídké vektory. Hustými vektory jsou považovány takové vektory, které obsahují minimální množství nulových hodnot, kdy řídké jich obsahují velké množství. V rámci této práce bude zkoumáno rozdělení dle Vajalla et al. (2020):

- **Diskrétní vektory**
  Vektorizační přístupy, jejichž výstupem jsou diskrétní vektory, patří mezi historicky nejstarší vektorizační techniky. Důvod proč jsou zvané diskrétní, je stanoven tím, že tyto přístupy pracují s jednotkami textu (slovy, n-gramy atd.) jako s atomickými jednotkami. Tato diskrétnost zabraňuje zachycovat vztahy mezi slovy (Vajalla et al., 2020).
  Základním přístupem pro tento typ vektorizace je namapování každého slova z textového korpusu do slovníku N. Každá věta či dokument v korpusu je poté prezentován jako N-dimenzionální vektor (Vajalla et al., 2020).
  Nejčastěji využívanou metodou tvorby diskrétních vektorů je bag-of-words (dále „BoW“). Pro nenulové hodnoty ve výsledných vektorech může být využita varianta binární (termín se v dokumentu vyskytuje či nevyskytuje) či varianta, kde je zahrnuta četnost (četnost určitého termínu v dokumentu). Velmi populární je také reprezentace TF-IDF, což je BoW varianta, u níž je cílem zahrnout i rozdílnou důležitost slov v dokumentech. Vektory dokumentů vytvořené pomocí variant BoW jsou si poté podobné v případě, že obsahují podobná slova.
  Tyto reprezentace jsou jednoduché na implementaci. Jejich nevýhodou ovšem je, že neumožňují zachycovat vztahy mezi slovy. Dále mají u větších korpusů vektory obrovskou velikost a jsou řídké. To značně zpomaluje rychlost zpracování takových vektorů. Diskrétní vektorizační přístupy taktéž neumí řešit případ, kdy má být vytvořen vektor pro dokument obsahující slovo či slova, jež nebyly přítomny v datech na učení.

- **Spojité vektory**
  Pro překonání nevýhod spjatých s diskrétními vektory byly vytvořeny tzv. spojité vektory, také označované jako „embeddingy“. Tyto metody využívají architektur neuronových sítí za účelem vytvoření hustých, nízkorozměrných reprezentací slov a textu (Mikolov et al., 2013). Tyto reprezentace o typické velikosti 50 - 500 prvků jsou výrazně menší než diskrétní vektory, které u větších korpusů mohou mít tisíce až dokonce miliony prvků. Učení algoritmů strojového učení spojitými vektory je tedy výrazně efektivnější než-li u vektorů diskrétních. Jsou ovšem také označovány jako statické embeddingy vzhledem k tomu, že pro každé specifické slovo, vyskytující se v textu v jiných kontextech, je vytvořena identická reprezentace. Hlavními vektorizačními přístupy v rámci této kategorie jsou FastText, Glove, Word2vec (Mikolov et al., 2013) a Doc2Vec (Mikolov et al., 2014)
- **Univerzální textové reprezentace**
  Univerzální textové reprezentace se objevily v roce 2018 s vytvořením tzv. ELMo (Embeddings from Language Models) (Peters et al., 2018). ELMo efektivně překonalo omezení spojitých vektorů, jež neumožňují zachycovat vektor slova na základě rozdílných kontextů. Bylo toho dosaženo zpracováním celé věty, kdy se vytvoří slovní embedding i s kontextem pomocí tzv. „bidirectional“ modelu jazyka. Tento model se skládá z několika vrstev LSTM (Long Short Term Memory) neuronové sítě, které jsou předučené na obrovském korpusu textových dat (Lauriola et al., 2022). Poté může být model dále doladěn (proces označovaný jako tzv. „fine-tuning“) na datech pro specifickou úlohu.
  Na ELMo navazuje vývoj tzv. transfomerů. jež stejně jako ELMo umožňují zachycovat vektor slova na základě kontextu. U transformerů je využito komplexní architektury, jež zahrnuje několik průchodů textem a několik čtení z zleva doprava i zprava doleva za účelem namodelování kontextu (Lauriola et al., 2022). Nejčastěji používaným transformerem pro NLP úlohy je v současnosti BERT od Google (Vajalla et al., 2020). Populárními jsou i jeho derivace, včetně DistilBERT (Vajalla et al., 2020), jež bude zaměřením i této práce.

V následujících sekcích budou objasněny vektorizační přístupy, s nimiž bylo dále experimentováno v rámci implementační části práce. Od každé kategorie bude využita alespoň jedna vektorizační technika (u spojitých vektorů techniky dvě).

3.6.1 TF-IDF

TF-IDF, neboli Term Frequency - Inverse Document Frequency, označuje vektorizační techniku pro tvorbu diskrétních vektorů z textových dat. Jde o variantu bag-of-words. Zásadním rozdílem TF-IDF oproti BoW je, že u této vektorizační techniky je brána v potaz váha jednotlivých slov v korpusu (u BoW mají všechna slova váhu stejnou). To je provedeno porovnáním daného slova se slovy ve stejném dokumentu, a také s celým korpusem.

Primární myšlenkou za TF-IDF je, že pokud se slovo t vyskytuje v dokumentu d mnohokrát, ale nevyskytuje se moc často v ostatních dokumentech, musí být slovo t pro daný dokument velmi důležité. Tedy důležitost slova t se musí zvyšovat úměrně k počtu výskytů v dokumentu d, ale zároveň úměrně snižovat k počtu výskytů v jiných dokumentech (Raschka, 2016).

Matematicky lze tyto vztahy vyjádřit hodnotami TF a IDF, které se poté navzájem násobí. TF, neboli Term Frequency, se dle Qaiser et al. (2018) vyjadřuje pro slovo t v dokumentu d následující matematickou rovnicí:

$$TF(t,d) = \frac{\text{Počet výskytů slova } t \text{ v dokumentu } d}{\text{Celkový počet slov v dokumentu } d} \tag{1}$$

IDF, neboli Inverse Document Frequency, se dle Qaiser et al. (2018) vyjadřuje pro slovo t následovně:

$$IDF(t) = log_e \frac{\text{Celkový počet dokumentů v korpusu}}{\text{Počet dokumentů obsahující slovo } t} \tag{2}$$

TF-IDF skóre pro slovo t je tedy:

$$\text{TF-IDF(t)} = \text{TF(t)} * \text{IDF(t)} \tag{3}$$

3.6.2 Word2vec

Word2Vec je mělká neuronová síť vytvořena Mikolovem et al. (2013). Word2Vec umožňuje vytvářet vektory, jež označujeme jako spojité, neboli tzv. embeddingy. Tyto embeddingy dokáží zachytit kontext slov.

Pro tvorbu vektorů v rámci NLP aplikace lze využít již předučený model či jej předučit na datech pro daný use-case. V případě učení vlastního modelu Word2Vec, je na základě textového korpusu vytvořen embedding pro každé slovo v korpusu, aby byl co nejlépe zachycen význam slov. Význam je určen na základě slov v kontextu učeného slova. Pokud se tedy dvě rozdílná slova často vyskytují v podobném kontextu, je velmi pravděpodobné, že jsou jejich významy taktéž podobné (Vajalla et al., 2020).

Bylo dokázáno, že Word2vec má schopnost zachytit obrovské množství přecizních syntaktických a sémantických vztahů mezi slovy (Lauriola et al., 2022). Například pokud je od Word2Vec vektoru slova „King“ odečteno „Man“ a přičteno „Woman“, výsledná vektorová reprezentace bude spjata se slovem „Queen“. Model Word2Vec dokáže zachytit mnoho dalších obdobných analogií (Mikolov et al., 2013).

Byly navrženy dva různé modely pro Word2Vec, a to CBOW a Skip-gram. CBOW je učen tak, aby mohl rekonstruovat cílové slovo na základě slov v jeho kontextu. Skip-Gram na druhou stranu predikuje slova v kontextu na základě zadaného cílového slova. U obou variant je taktéž řada hyperparametrů, jež musíme zvolit. Příkladem je kontextové okno, jež určuje, kolik slov od učeného slova má být bráno v potaz při učení modelu. Dalším je také velikost výsledných vektorů, které jsou pro

slova vytvořena. Standardně je pro Word2Vec velikost vektorů mezi 50 a 500 prvky. Rozhodnutí jaké hodnoty hyperparametrů zvolit, je nutné prozkoumat především experimentací.

I přes značné výhody Word2Vec, neumí tato vektorizační technika (stejně jako TF-IDF) zachycovat vektory pro tzv. out-of-vocabulary (dále „OOV“) slova. Jde o slova, jež nebyly přítomné v datech při učení modelu, a model tedy pro ně neumí vytvořit textovou reprezentaci. Řešením této situace je zvýšit množství dat na učení, čímž je zvýšena pravděpodobnost, že slovo bude při učení zachyceno. Dále je možné využít jinou vektorizační techniku jako např. FastText od Facebook. Ta vektorovou reprezentaci vytváří na základě tzv. n-gramů (přípon, předpon, kořenů atd.) jednotlivých slov.

Word2Vec vytváří vektory pouze pro slova. Ve většině NLP aplikací je však nutné reprezentovat větší atomické jednotky jako celé věty, odstavce či dokumenty. Jednoduchým přístupem jak reprezentovat delší texty pomocí Word2Vec je kombinací jednotlivých embeddingů slov vyskytujících se v daném textu. Nejčastěji jsou embeddingy slov sečteny či je z nich vytvořen průměr (Vajalla et al., 2020).

3.6.3 Doc2vec

Doc2Vec je rozšířením modelu Word2Vec vytvořený v roce 2014 Mikolovem et al. Jde o jednoduchou extenzi z učení reprezentace slov na učení reprezentací sekvencí slov. Může jít o o pouhou kratší sekvenci slov, větu, odstavec či celý dokument (Lau et al., 2016). Bez ohledu na velikost zpracovávaného textu umožňuje Doc2Vec vytvořit vektory konstantní délky. Jedná se o první široce dostupnou implementaci umožňující získání embeddingů pro celý text místo kombinace slovních vektorů (Vajalla et al., 2020).

Doc2Vec má velmi podobnou architekturu Word2Vec. Výjimkou však je, že kromě slovních vektorů se Doc2Vec učí i tzv. odstavcový vektor, který reprezentuje celý daný text. Tyto odstavcové vektory jsou pro každý dokument unikátní. Na druhou stranu, slovní vektory tvořící jednotlivé celé texty mají v různých částech textu stejnou podobu. Jakmile je Doc2Vec model naučen, je odstavcový vektor pro nové texty dedukován tím, že se využijí slovní vektory získané při procesu učení modelu (Mikolov et al., 2014).

Stejně jako u Word2Vec, má Doc2Vec model dvě varianty. Existují varianty zvané Distributed Bag-Of-Words (dále „DBOW“) a Distributed Memory Paragraph Vectors (dále „DMPV“). Obě varianty mají své výhody a nevýhody.

DBOW pracuje na stejném principu jako Skip-gram model spjatý s Word2Vec, s tou výjimkou, že vstup je nahrazen speciálním tokenem reprezentujícím daný dokument. U této varianty je ignorováno pořadí slov (Lau et al., 2016).

DPMV je více komplexní model s více parametry než-li DBOW. Analogií této architektury je varianta Word2Vec modelu CBOW. U DMPV se ovšem vektory nesčítají, ale spojují. Opět je zde cílem předpovědět kontextové slovo na základě spojeného dokumentového a slovního vektoru (Lau et al., 2016).

Mikolov et al. (2014) považují DPMV jako lepší model, zatímco jiní autoři uvádějí že DBOW si vede na mnoha úlohách konzistentně lépe (Lau et al., 2016). Lau et al. (2016) také zjistili, že pro reprezentaci vět je optimálnější využít techniky zprůměrování Word2Vec vektorů (Lau et al., 2016).

3.7 Klasifikátory

Klasifikátor označuje algoritmus strojového učení s učitelem. Je používán pro klasifikaci, kategorizování či labelování datových bodů na základě dříve identifikovaných vzorech v datech na učení (Sarkar, 2016). Textová klasifikace byla detailněji popsána v kapitole 3.4.1.

Textových klasifikátorů je dostupné velké množství. Některé klasifikátory mohou být pro určitý charakter dat a využívané reprezentace lepší než jiné. Nelze ovšem nikdy předem určit jaký klasifikátor je pro daný use-case optimální.

Tato kapitola poskytuje přehled malé množiny klasifikátorů, které jsou poté využity v rámci implementační části této práce:

Naive Bayes
Naive Bayes je klasický algoritmus pro klasifikační úlohy založený na tzv. Bayes teorému (Joyce, 2003). Pomocí tohoto algoritmu se vypočítá pravděpodobnost náležitosti datové instance k třídě. Poté se konečný label přiřazuje, dle toho, jaká pravděpodobnost je nejvyšší.

Charakteristikou algoritmu je, že předpokládá, že každý rys v datech je nezávislý na ostatních. To většinou neodpovídá realitě, tento algoritmus je ovšem i tak často používán jako první algoritmus pro textovou klasifikaci. Je to z důvodu jednoduchosti a lehké implementace algoritmu (Vajalla et al., 2020).

Algoritmus Naive Bayes má dále několik variant.V rámci této práce budou upřesněny dvě:

- **Multinomiální Naive Bayes** – Pro predikci využívá četnost výskytu rysů. Používá se pro klasifikační problémy, kde jsou reprezentace textu diskrétní (Ersoy, 2021).
- **Gaussian Naive Bayes** – Pro predikci se zde využívá střední hodnota z hodnot atributů dat, které mají normální rozdělení. Používá se pro klasifikační problémy, kde jsou reprezantace textu spojité (Ersoy, 2021).

Random Forest
Random Forest klasifikátor lze považovat jako kolekci rozhodovacích stromů, kdy každý strom provádí samostatnou predikci. Takový klasifikátor se označuje jako tzv. „ensemble“ model a výsledná predikce je kombinací všech predikcí. Díky využití této metody je výsledný klasifikátor robustní vůči v šumu v datech. Je taktéž možné vybrat množství stromů, kdy více stromů poskytuje kvalitnější výsledky za cenu vyšších výpočetních nároků (Raschka, 2016)

Support vector machine
Support Vector Machine (dále „SVM“ je dalším populárním klasifikačním algoritmem. Cílem jakéhokoliv klasifikátoru je naučit se hranici, která funguje oddělovač mezi různými třídami textu. Tato hranice může být lineární či nelineární. Cílem SVM je tedy naučit se tuto optimální hranici, tak aby byly body mezi jednotlivými třídami od sebe co nejvíce vzdálené. Stejně jako Random Forest je SVM robustní v situacích, kdy je v datech pro učení velké množství variace a šumu. Nevýhodou je relativně dlouhá doba učení modelu (Vajalla et al., 2020).

Logistická regrese
Klasifikátor logistické regrese je primárně binárním klasifikátorem. Tento model se učí váhy individuálních rysů na základě toho, jak jsou důležité pro finální klasifikační rozhodnutí. Cílem logistické regrese je naučit se lineární oddělovač mezi třídami v datech na učení s cílem maximalizovat pravděpodobnost dat. Toto učení vah rysů a distribuce pravděpodobnosti napříč všemi třídami je provedeno tzv. „logistickou“ funkcí. Od toho je odvozen i název klasifikátoru (Vajalla et al., 2020).

K-nearest neighbors
K-nearest neighbors (dále „KNN“) je klasifikační algoritmus, zásadně odlišný od klasifikátorů předešlých. Predikci totiž provádí „zapamatováním“ si datasetu na učení. Na nové datové instance je poté predikován label v třech následujících krocích (Raschka, 2016):

1. Výběr hodnoty k a metriky pro vzdálenost
2. Nalezení k nejbližších sousedů pro datový vzorek, který chceme klasifikovat
3. Dle kategorie, jež má většinu hlasů, přiřadit label

Hlavní výhodou KNN je, že klasifikátor se okamžitě adaptuje s kolekcí více dat na učení. Nevýhodou může být, že s vyšším počtem datových instancí v datasetu pro učení lineárně roste časová náročnost predikce nového vzorku.

3.8 Transformery

V kapitole 3.6 byly popsány transformery, včetně jejich možného využití jako vektorizačních technik. V této sekci budou dále upřesněny, a to i s dalšími možnostmi využití, které jsou relevantní k této práci.

Transformery jsou v současnosti jedním z hlavních pilířů NLP aplikací (Lauriola et al., 2022). Značně změnily směr této oblasti díky aplikaci tzv. „self-attention“ mechanismu. Díky tomu je jejich předučení výrazně rychlejší než-li u dříve často využívaných rekurentních a konvolučních neuronových sítích, které zpracovávají text sekvenčním způsbem. Self-attention mechanismus transformerům umožňuje paralelně zpracovat tzv. „attention“ skóre pro každé slovo ve větě či dokumentu za účelem namodelování vlivu, jež na sebe slova mají. (Minaee et al., 2020).

Tento self-attention mechanismus také transformerům dovoluje vytvořit stejným slovům odlišnou reprezentaci, dle toho v jakém kontextu se vyskytuje (Vajalla et al., 2020). Tuto schopnost nemá žádná jiná diskrétní či spojitá vektorizační technika popisovaná v předchozích sekcích.

Pro transformery lze taktéž využít metoda zvaná „transfer learning“. Myšlenkou této metody je aplikace znalostní získaných z řešení určité úlohy na úlohu jinou. V případě transformerů je transformer předučen na korpusu textových dat extrahovaných z celého internetu (v některých případech o velikosti až 40GB). Poté je proveden tzv. „fine-tuning“ proces neboli doladění. V rámci tohoto dodatečného procesu se dále model adaptuje na práci v rámci cílové domény a pro cílovou úlohu (Vajalla et al., 2020). Díky tomu, že byly modely předučeny na obrovském množství textových dat určitého jazyka, umí často rozlišit v textu mnoho nuancí. O to kvalitnější mohou být vektorové reprezentace vytvořené transformery.

Ve většině případů je využito procesu doladění, pro specifickou NLP úlohu je však možné model i předučit. K tomu je ovšem vyžadováno obrovského množství dat a výpočetního výkonu. I proto byly vytvořeny různé varianty transformerů pro použití v různých doménách (např. zdravotnictví, finance atd.).

V současnosti je nejpopulárnějším transformerem BERT (Bidirectional Encoder Representations from Transformers) od Google. BERT využívá specifickou metodu předučení využitím tzv. „Masked Language Model“ a „Next Sentence Prediction“. V rámci MLM síť BERTu zamaskuje malé množství slov na vstupní sekvenci a poté se tyto slova snaží predikovat na výstupu. NSP označuje schopnost sítě pochopení vztahů mezi větami pomocí binární ztráty. To znamená, že se snaží určit, zda věty následují po sobě (Lauriola et al., 2022).

Jako u jiných transformerů se zde využívá self-attention mechanismu a taktéž tzv. Wordpiece algoritmu. Ten má velmi podobný princip jako fastText model, kdy jsou slova na vstupu BERTu, rozdělena na menší atomické jednotky, a až poté se z nich vytvoří vektorové reprezentace. V základní podobě může BERT zpracovat v rámci každého vstupu maximálně 512 těchto tokenů (Devlin et al., 2018).

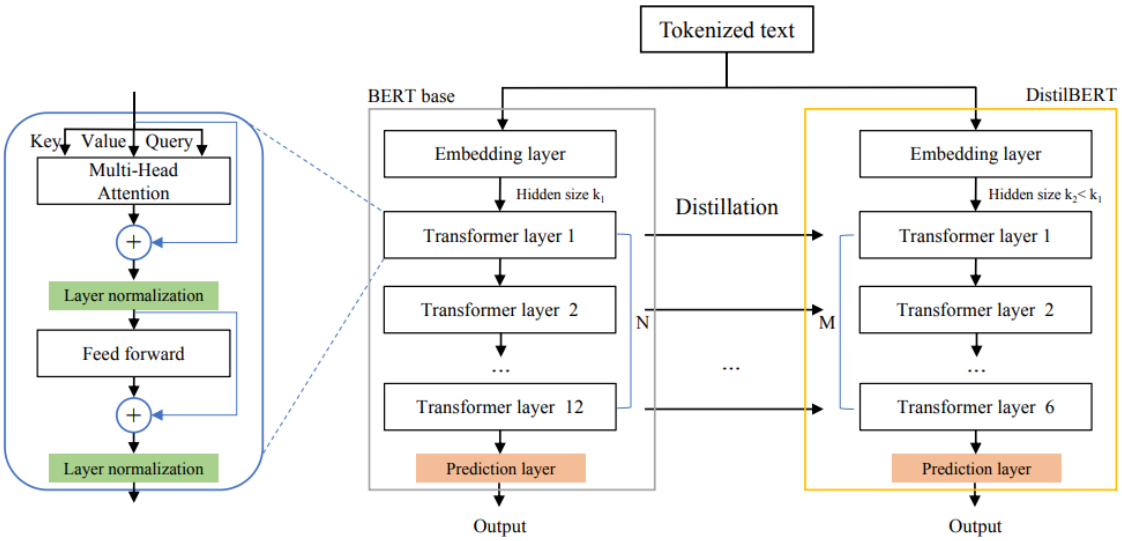
BERT byl inspirací pro vznik mnoha dalších transformerů, využívající jinou datovou doménu pro předučení modelu či nabízející vyšší rychlost. Příkladem druhé kategorie je např. DistilBERT, který bude tématem další podsekce.

3.8.1 DistilBERT

DistilBERT, neboli „Distilled BERT“, je kompaktní verze transformeru BERT.

DistilBERT má stejnou obecnou architekturu jako BERT. DistilBERT je však výrazně kompaktnější díky aplikování metody známé jako „destilace znalostí“ na BERT. Tato metoda umožňuje replikovat většinu schopností většího modelu v rámci modelu menšího. Velikost DistilBERT je tedy o 40% nižší. Dále má oproti 12 transformer vrstvám přítomným v BERT, vrstev pouze 6. Ve zbývajících vrstvách byly taktéž provedeny menší změny s cílem zvýšení efektivity modelu. Celkový počet trénovatelných parametrů přítomných v DistilBERT je zhruba poloviční, tedy

přibližně 66 milionů (Sanh et al., 2019).



Obrázek 1: Architektura distilBERT, její komponenty a porovnání s BERT
Zdroj: (Adel , 2022)

I přes tyto drastické redukce má DistilBERT 97% schopnost chápat jazyk jako BERT a je taktéž o celých 60% rychlejší. Výsledkem je, že je také rychlejší tento model předučit i doladit. Zabírá rovněž méně paměti a to do takové míry, že jej lze využívat i na mobilních zařízeních (Sanh, 2019).

DistilBERT (i BERT) má v rámci klasifikačních úloh dvojí uplatnění. Lze jej v první řadě pro klasifikační úlohy jako vektorizační technika, kdy jsou pro text vytvořeny embeddingy. Ty jsou poté použity pro klasifikaci pomocí klasifikačních algoritmů, např. těch uvedené v sekci 3.7. Druhou možností je využít DistilBERT pro vytvoření embeddingů, ale rovněž hned poté provést samotnou klasifikaci. Je nutné podotknout že v rámci doladění DistilBERT se využívá i tzv. validační dataset, který slouží k ladění parametrů výsledného transformeru.

3.9 Evaluace

Klíčovou fází jakékoliv NLP aplikace pro textovou klasifikaci je měření toho, jak dobře model klasifikuje. Obecně se toto meření provádí dle výsledků klasifikátoru na ještě neviděných datech (Vajalla et al., 2020).

Úspěch lze dle Vajalla (2020) měřit na metrikách dvojího typu, vnější a vnitřní. V podnicích je každý model umělé inteligence nasazen pro řešení určitého podnikového problému. Jako vnější metriky se tedy označují takové ukazatele, který určují, do jaké míry je splněn tento hlavní cíl. Vnější evaluace započíná vytvořením podnikových metrik a procesu pro jejich měření na začátku projektu. Model, který sice skvěle klasifikuje, ale nedosahuje dostatečně dobrých skóre vnějších metrik nelze považovat za úspěšný (Vajalla et al., 2020). Vnější metriky se měří až po nasazení modelu do reálného provozu.

Dalším typem metrik jsou vnitřní. Vnitřní metriky se měří na základě výsledků predikce klasifikátoru na neviděných datech. Typickým ukazatelem výsledků binárního klasifikátoru je tzv. „matice záměn“. Dále se často využívají accuracy, precision, recall a F1 skóre. V menší míře také ROC a AUC. Ve zbývající části sekce budou tyto pojmy objasněny.

Matice záměn

Matice záměn, neboli anglicky „confusion matrix“, označuje vizuální evaluaci, která umožňuje zkoumat opravdový a předvídaný výstup pro kategorie datasetu (Vajalla et al., 2020). Jde o čtvercovou matici, jež vykazuje počet identifikovaných skutečných pozitiv, skutečných negativ, falešných pozitiv a falešných negativ, které klasifikátor predikoval (Raschka, 2016).

Tyto pojmy mají v evaluaci následující význam:

- **Skutečná pozitiva** – Označované také jako True Positives (TP). Jde o datové instance z pozitivní kategorie, které byly správně klasifikovány jako pozitivní.
- **Skutečná negativa** – Označované také jako True Negatives (TN). Jde o datové instance z negativní kategorie, které byly správně klasifikovány jako negativní.
- **Falešná pozitiva** – Označované také jako False Positives (FP). Jde o datové instance z pozitivní kategorie, které byly špatně klasifikovány jako negativní.
- **Falešná negativa** – Označované také jako False Negatives (FN). Jde o datové instance z negativní kategorie, které byly špatně klasifikovány jako pozitivní.

Lze tedy usoudit, jaký by byl bezchybný binární klasifikátor. Byl by to takový, který vyhodnotí všechny instance tříd jako buď TP či TN. Současně by byly FP a FN nulové.

Hodnoty obsažené v matici záměny jsou dále použity pro výpočet metrik jako accuracy, precision, recall a F1 skóre.

Accuracy

Accuracy definuje podíl správných predikcí z celkového počtu provedených predikcí klasifikátoru (Vajalla et al., 2020). Využití accuracy jako jediné metriky pro evaluaci modelu v případě, že data jsou nevyrovnaná, není doporučováno, jelikož to může být zavádějící (Paramesh et al., 2019).

$$Accuracy = \frac{TN + TP}{TP + TN + FP + FN} \tag{4}$$

Precision
Precision určuje jak přesné jsou predikce klasifikátoru. Tedy na základě všech predikcí pozitivní třídy, precision určuje kolik z nich bylo skutečných. Může jít o důležitou metriku v případech kdy jsou chyby ve vztahu k pozitivní třídě mnohem dražší než u třídy negativní (např. u predikce šíření chorob ve zdravotnictví) (Vajalla et al., 2020).

$$Precision = \frac{TP}{TP + FP} \tag{5}$$

Recall
Recall je metrikou doplňující precision. Zachycuje, kolik z predikcí pozitivní třídy jsou ve skutečnosti pozitivní. Je používaný pro klasifikační úlohy, kde je získání pozitivních výsledků nejdůležitější (Vajalla et al., 2020).

$$Recall = \frac{TP}{TP + FN} \tag{6}$$

F1
F1 skóre je harmonickým průměrem precision a recall (Minaee et al., 2020). Často se spolu s accuracy používá pro celkové ohodnocení výsledků modelu (Vajalla et al., 2020).

$$F1 = 2 * \frac{precision * recall}{precision + recall} \tag{7}$$

3.10 Existující řešení

V rámci této sekce budou shrnuty projekty a vědecké publikace zabývající se obdobným tématem jako tato práce. Půjde především o takové práce zaměřující se na problematiku klasifikace zákaznických incidentů, pracují s daty v podobné doméně či v prostředí SAP.

První zkoumanou prací je diplomová práce Automatická kategorizace zákaznických incidentů. Autor v rámci implementace provedl přes tisíc experimentů za účelem nalezení optimálního klasifikátoru pro danou úlohu. Autor zde implementoval klasifikaci jak pomocí TF-IDF, tak i BERT. U první reprezentace bylo provedeno předzpracování zahrnující odstranění znaků nového řádku, odstranění ne-alfanumerických znaků, převod na malá písmena, odstranění stop slov a tokenizace. Pro BERT byla data pouze očištěna od metadat, HTML tagů a dalších nežádoucích prvků. U dat pro učení modelu bylo dále provedeno mnoho experimentů zahrnující techniky pro vyvážení datasetu jako náhodné převzorkování, podvzorkování, duplikace datových instancí, augmentace pomocí strojového překladu či aplikace metody SMOTE. Pro evaluaci klasifikace bylo využito accuracy, precision, recall a F1 skóre. Jako nejlepší klasifikační model se osvědčil doladěný BERT, a to v kombinaci s aplikací metody pro vyvážení datasetu zvané „back translation“ (Koukal, 2022).

Další práce se zabývá klasifikátorem incidentů v prostředí SAP. Klasifikace probíhala na třech úrovních, kdy u nových incidentů byla predikována úroveň podpory, spjaté oddělení a spjatý produkt. K reprezentaci textu bylo využito TF-IDF. Ke klasifikaci bylo využito SVM, Random Forest, Naive Bayes, logistické regrese a KNN. Bylo také porovnána klasifikace při použití celého textu incidentů či kombinace celého textu a kategorie. K evaluaci se využilo stejných metrik jako u předchozí zkoumané práce. Specifické pro tuto práci bylo využití relativně extrémně malého datasetu čítajícího 732 incidentů. Pro vyvážení tohoto datasetu bylo využito náhodného převzorkování a podvzorkování. Využití jak textu tak kategorie a klasifikace pomocí Random Forest přinesla nejlepší výsledek a to F1 skóre s hodnotou 83% (Fuchs et al., 2022).

Další práce se taktéž zaměřuje na klasifikaci incidentů, konkrétně z kategorie IT a HR, v prostředí SAP. Cílem této práce je pomoci uživatelům service desku vybrat správnou kategorii incidentu, a to na základě textu popisující jejich problém. Dle tohoto popisu by výsledný model nabídl uživateli 5 kategorií, jež byly klasifikovány jako nejpravděpodobnější kategorie pro daný text. Práce je význačná predikcí kategorie textu z 2900 možných tříd v kategorii IT a 1400 možných tříd v kategorii HR. Vnější metrikou, na kterou bylo v rámci práce zaměřeno, bylo snížení času, jež uživatelé vynaloží na hledání patřičné kategorie daného incidentu. Dále bylo cílem snížit četnost situace, kdy musí být kategorie incidentu zadána týmem podpory. Práce je koncipována jako dvoufázový klasifikátor. V první řádě je incident klasifikován jako buď IT či HR incident. V druhé fázi je již predikována samotná kategorie incidentu. Pro učení klasifikátorů se zde využívá téměř 6 milionů incidentů, kdy jsou zde porovnány vektorové reprezentace pomocí jak TF-IDF, tak FastText. Jsou zde také prozkoumány různé varianty předzpracování specifické pro SAP incidenty. Mnohé incidenty např. obsahují HTML tagy, a jsou proto odstraněny. Dále bylo zjištěno, že většina incidentů je v angličtině, zatímco některé jsou v němčině, francouzštině, čínštině či korejštině. Před vytvořením reprezentací pro text takových incidentů, byly z dat na učení tyto incidenty odstraněny. Další důležitou znalostí je, že incidenty obsahují mnoho klíčových slov specifických pro SAP, jako systémová jména, SAP produkty a interní SAP termíny, jež jsou velmi důležité pro klasifikační proces. Není tedy vhodné používat předučené slovní embeddingy. Dále byly prozkoumány tradiční kroky předzpracování jako odstranění duplikátů, stop-slov, stematizace, lematizace atd. Po objevení nejlepší kombinace po předzpracování a naučení modelů bylo zjištěno, že reprezentace textu pomocí TF-IDF vedla k lepším výsledkům klasifikátoru než-li FastText. Nejlepší výsledek byl ovšem dosaženo pomocí ensemble techniky, kdy byly obě metody reprezentace kombinovány. Evaluace byla provedena pomocí precision, recall, F1 a také mikro, makro a váženého F1 skóre (Opuchlich, 2019).

Další velmi důležitou zkoumanou prací je současně paralelně budovaný klasifikační systém v prostředí SAP, na kterou tato práce i navazuje. Tento systém má za cíl klasifikovat incidenty jako spjaté s migrací či upgrade (tedy se situacemi popsanými v podsekcích 3.1.1 a 3.1.2). V případě že je jedna věta daného inciden-

tu klasifikována jako upgrade/migrace, je poté do této kategorie klasifikován celý incident. Vzhledem k tomuto charakteru klasifikačního procesu se v první řadě na každém incidentu provede segmentace na věty. Poté je na základě vět, jež byly v dřívějších projektech označeny jako věty obsahující šum, natrénován Doc2Vec model. Pro věty v určitém incidentu jsou poté pomocí tohoto modelu vytvořeny embeddingy. V případě že má určitá věta alespoň 80% kosinovou podobnost s nějakou z vět označené jako šum, je odstraněna. V ideálním případě by poté další kroky měly být prováděny s větami, jež obsahují jen funkční znalosti a nejsou pouze šum. Každá věta je poté předzpracována HTML parsováním, tokenizací, lematizací, procesem POS tagging, aplikací regex výrazů pro odstranění speciálních znaků a odstranění stop slov na základě defaultního seznamu z python knihovny *nltk*. Následuje vytvoření vektorové reprezentace pro věty pomocí druhého Doc2Vec modelu, který je učen na předzpracovaných větách pro cílovou úlohu.

Veškeré informace ještě nejsou známy vzhledem k tomu, že se na projektu stále pracuje. Důležitý je hlavně výstup toho systému, jelikož se podle toho bude implementovat klasifikátor v rámci této práce.

Tato práce je taktéž provázána s druhým projektem v prostředí, který má předchozí projekt, ale i tuto práci doplňovat. Jedná se o klasifikátor nikoliv incidentů, ale Notes. Jak již bylo zmíněno, Notes jsou návody pro korekci technických problémů v rámci SAP produktů. Tento klasifikátor má za úkol klasifikovat Notes jako relevantní v případě, že jsou spjaty pro řešení problémů spjaté s migrací či nerelevantní, jestli nikoliv. Dataset tvoří 427 Notes, jež byly zařazeny do kategorie pro řešení migračních problémů. Na základě této množiny dat bylo cílem identifikovat co nejvíce dalších Notes patřící do stejné kategorie.

4 Metodika

V rámci této kapitoly bude objasněn postup tvorby řady experimentů za účelem nalezení vhodného modelu pro binární klasifikaci. Bude zde zahrnuto co nejvíce informací, jako použité prostředky a data, pro možnost replikace výsledků.

4.1 Použité prostředky

Hardware
Při práci na tomto projektu nebylo možné experimenty implementovat na lokálním prostředí. To je odůvodněno citlivou povahou dat, s kterými bylo nakládáno. Veškerý hardware využívány v rámci této práce byl tedy zprostředkován skrze zabezpečenou cloud platformu Kubeflow provozovanou na serverech společnosti SAP. Přes tuto platformu byl vytvořen virtuální server, pro který bylo rezervováno 10GB RAM paměti a 1 procesor Intel Xeon Platinum 8260.

Software
Pro implementaci práce bylo využito vývojové prostředí *Jupyter Lab* verze 3.0.16 hostovaném na popsaném serveru. Veškerá implementace byla provedena v programovacím jazyku *Python* verze 3.8.10. Důvod volby tohoto jazyka je především možnost využití širokého množství knihoven zaměřených na oblast strojového učení. Význačnými knihovnami tohoto typu použité v rámci implementace byly např. *scikit-learn*, *nltk*, *gensim* a *transformers*.

Pro zobrazování informací k jednotlivým incidentům bylo využito dedikovaného service desku od společnosti SAP. Pro vytvoření olabelovaného datasetu se využívalo aplikace Microsoft Excel.

4.2 Data

V rámci této sekce bude v první řadě popsán formát a charakteristické znaky incidentů. V druhé řadě bude popsán proces tvorby datasetu, jež se poté využíval v dalších sekcích práce.

Incidenty v SAP
Jak již bylo zmíněno v sekci 3.2, incidenty mají v rámci SAP mnoho strukturovaných polí (viz příloha A). Tyto pole lze mnohdy využít v rámci klasifikace incidentů, jak bylo zmíněné v práci od Fuchs et al. (2022). Textové hodnoty, jež by u SAP incidentů mohly být relevantní pro klasifikaci, jsou např.:

- **nadpis** – Textová hodnota identifikující daný incident.
- **popis** – Krátký textový popis v rámci něhož je specifikován problém, kvůli kterému byl incident vytvořen. Zahrnuje i kroky pro reprodukci daného problému.

- **komunikace** – Záznam veškeré výměny zpráv mezi zákazníkem a zaměstnanci podpory společnosti SAP. Zprávy jsou v textové podobě. U každé zprávy je uvedeno, kdy byly odeslány v podobě datumu a času.
- **komponenta** – Identifikuje specifickou podnikovou oblast, k níž incident náleží. Jde o textový řetězec typicky ve formátu „XX-XX-XX“. První dvojznak určuje podnikovou oblast. Další dvojznaky poté tuto oblast dále zužují.
- **produkt a verze** – Produkt a verze produktu, s nímž je spjat daný incident. Opět jde o textovou hodnotu.
- **priorita** – Priorita určující, jak závažný je problém pro zákazníka. Určuje, kolik zdrojů je společností SAP vykládáno pro řešení problému. Jde o textový řetězec. Povolené hodnoty jsou „Low“, „Medium“, „High“ a „Very high“. U priority označené „Very high“ je poskytnuta 24hodinová podpora za účelem poskytnutí co nejrychlejšího řešení problému.

V rámci experimentů této práce byly zvoleny dvě kombinace využití těchto textových hodnot. V první řadě se využilo kombinace zahrnující nadpis a popis. V rámci druhé kombinace se využilo nadpisu, popisu a komunikace.

Jak také bylo zmíněno v práci od Opuchlich (2019) textové hodnoty incidentů společnosti SAP mají určité charakteristické znaky. Jedná se o hodnoty polí nadpis, popis a komunikace.

V první řadě probíhá komunikace v rámci incidentů obdobně jako při emailové komunikaci. V obsahu jedné zprávy tedy může být obsažena i zpráva předchozí, v komunikačním poli se tedy může vyskytnout mnoho duplicitních vět. Incidenty také často mohou být bilingvní. Typicky se v incidentech používá angličtina, ovšem často se v nich může současně vyskytovat i text v jazyku německém, čínském, korejském či francouzském. Obecně řečeno lze říct, že incidenty také obsahují, alespoň s ohledem na cíl této práce, velmi vysoké procento šumu. Text taktéž velmi často plný mnoha klíčových slov specifických pro SAP produkty.

Tyto charakteristické vlastnosti dat použitých v této práci musí být tedy reflektovány v implementaci klasifikačního systému.

Vytvoření datasetu

Za existenci společnosti SAP bylo zákazníky skrze service desk této společnosti vytvořeno několik milionů incidentů. V rámci této práce však bylo nutné klasifikovat pouze data z incidentů spjatých s upgrade či migrací, což je jen malý zlomek z celkového množství incidentů. Vzhledem k tomu, že žádný olabelovaný dataset zahrnující tyto kategorie v době vytváření systému nebyl k dispozici, musel být tedy vytvořen manuálně, a to olabelováním incidentů. Proces labelování je však ve většině situací velmi časově náročný. S ohledem na zvýšení efektivity labelovacího procesu, proto bylo tedy žádoucí vybrat takovou množinu incidentů, u nichž byla vysoká pravděpodobnost, že budou náležet k požadovaným třídám. Toho bylo v rámci tohoto projektu docíleno vyfiltrováním incidentů na základě třech kritérií.

V první řadě byly z výběru dat odstraněny incidenty na základě data vytvoření. Možností bylo datum 1. leden 2016. S ohledem na vývoj S/4HANA toto datum označuje milník, kdy vůbec mohla situace spjatá s migrací či upgrade nastat a být tedy i popsána v incidentech. Na základě zkušeností z předchozích projektů bylo ovšem nakonec využito data 1. leden 2019.

Za druhé byly využity tzv. SAP „komponenty“. Komponentu lze definovat jako určitou, velmi specifickou podnikovou oblast, kdy každý incident pod nějakou spadá. Bylo tedy vybráno 180 komponent, jež mají úzkou souvislost se scénářem migrace a upgrade. Dataset se tedy zúžil pouze na ty incidenty, jež spadají pod alespoň jednu z těchto komponent.

V poslední řadě bylo využito znalostí získaných v předchozím klasifikačním projektu zmíněného v sekci 3.10. V rámci této práce bylo vybráno 427 Notes spjatých s migrací či upgrade. Incidenty velmi často na tyto Notes odkazují. Finální množina dat tedy byla filtrována pouze na ty incidenty, jež odkazují na alespoň jednu z této množiny Notes.

Na základě těchto kritérií byla získána množina dat čítající 8763 incidentů. Dalo se také očekávat že značná část těchto incidentů budou spjaté s migrací či upgrade. V případě, že by bylo toto množství incidentů vybráno náhodně, jen zlomek z nich by byl spjat s požadovanými kategoriemi.

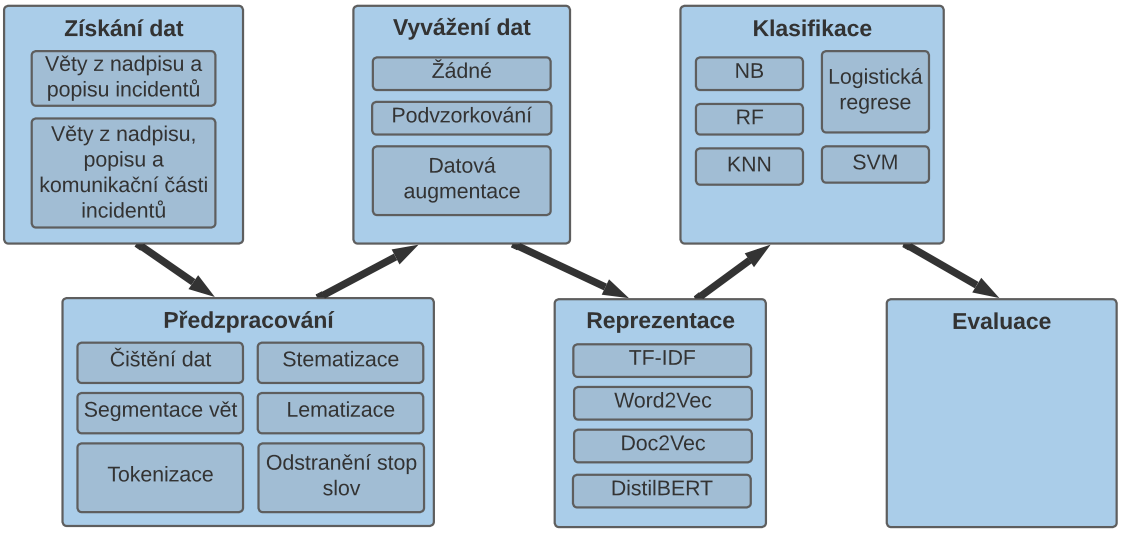
Následným cílem labelovacícho procesu bylo vytvoření datasetu z této množiny dat zahrnující co nejvyšší množství incidentů spjatých s upgrade a migrací.

Labelování bylo provedeno manuálně. U každého incidentu se zkoumala textová hodnoty nadpisu, popisu a komunikace. Dle významu textu a použité terminologie poté byly incidenty děleny do kategorií upgrade, migrace a nerelevantní. Nerelevantní incidenty nebyly dále v této práci využity.

Výsledkem procesu bylo olabelování více než 1800 incidentů, z nichž bylo 183 označeno jako upgrade, 844 jako migračních a 797 jako nerelevantních.

4.3 Experimenty

V této sekci bude popsána volba a provedení všech vykonaných experimentů této práce.



Obrázek 2: Přehled zkoumaných možností v rámci jednotlivých kroků experimentů

4.3.1 Předzpracování dat

Textová data získaná z olabelovaných incidentů bylo nutné dále předzpracovat. Bylo využito využito řady předzpracovacích technik, kde přesná forma předzpracování záležela na zvolené reprezentaci dat daného experimentu.

U spojitých a diskrétních vektorů se v první řadě naparasoval HTML text polí nadpis, popis a komunikace u všech incidentů vytvořeného datasetu. Tím byly odstraněny neužitečné informace jako HTML tagy a metadata. Dle typu experimentu se následně buď nadpis a popis či nadpis, popis a komunikační část incidentů segmentovaly na věty pomocí python knihovny *spaCy*.

Věty poté byly dále převedeny na lowercase, tokenizovány, a stematizovány. Lematizace byla provedena pomocí python knihovny *wordnet*. Byly také odstraněny speciální znaky.

Takto takto předzpracované věty byly dále filtrovány. Pokud nebyl jazyk věty identifikován jako angličtina, byla věta odstraněna. Vyfiltrovány byly také ty věty, které měly méně než 3 slova.

Dle výsledků analýzy byly na získaném datasetu vět zjištěno, že převážná část vět obsahovala pouze šum a nepřispívaly tedy ke zlepšení výsledků klasifikátoru. Bylo tedy uplatněno znalostí a dat získaných ze souběžně budovaného klasifikačního systému popsaného v sekci 3.10. V první řadě se využil Doc2Vec model, který byl naučen na větách incidentů, dříve identifikovaných jako šum. Tento model se použil

pro vytvoření vektorové reprezentace pro každou z vyfiltrovaných vět incidentů získaných rámci této práci. V případě, že jakákoliv věta měla alespoň 80% kosinovou podobnost s jakoukoliv větou z množiny vět označených jako šum, byla odstraněna. Pomocí tohoto procesu lze očekávat, že byla odstraněna převážná většina vět, jež by měly negativní dopad na výsledky klasifikace.

Tabulka 1: Přehled množství datových vzorků pro učení modelu

Využitá pole incidentů	**Počet upgrade vět**	**Počet migračních vět**
Nadpis + popis	1102	4523
Nadpis + popis + komunikace	11235	38850

Pro DistilBERT bylo kvůli zachování kontextových informací, tedy i vytvoření co nejkvalitnějších reprezentací vět, použito po segmentaci na věty jen naparsování HTML textu a odstranění speciálních symbolů.

4.3.2 Vyvážení dat

Vzhledem ke značnému nevyvážení obou kategorií dat bylo v rámci této práce experimentováno s dvěma metodami pro jejich vyvážení:

- **Náhodné podvzorkování** - V rámci náhodného podvzorkování bylo identifikováno množství vět spadající pod upgrade kategorii. Poté bylo náhodně vybráno toto množství vět z datové množiny migračních vět. Toto bylo provedeno jak pro věty z menší datové množiny polí nadpisu a popisu incidentů, tak i pro věty z větší datové množiny popisu, nadpisu a komunikace. V obou případech bylo podvzorkování provedeno pro celý dataset, čímž tedy byla úměrně snížena množina dat pro učení a testování (popř. i validaci).
- **Datová augmentace** - Další zvolenou metodou vyvážení vět byla datová augmentace pomocí back translation, neboli zpětného překladu. Pomocí knihovny *transformers* bylo 400 vět u menší datové množiny vět z kategorie upgrade přeloženo do němčiny a poté zpět do angličtiny. Výsledkem jsou poté věty, jež jsou významem velmi podobné větám původním, ovšem mají většinou pár slov nahrazeno synonymy. Takto vytvořené věty jsou přidány k původní množině dat (včetně příslušného labelu). U větší datové množiny vět bylo takto augmentováno 4000 vět. Je ovšem nutné podotknout, že takto datově augmentované vzorky byly ve všech případech používány čistě pro učení modelů. To je odůvodněno tím, že datově augmentované věty nereflektují reálnou podobu vět z incidentů. Jejich zahrnutí do testovací či validační množiny by tedy zkreslilo výsledky klasifikace.

  Data byla také využita pro učení modelů v nezměněném poměru mezi větami spjaté s upgrade a migrací.

4.3.3 Rozdělení dat

Pro textové reprezentace TF-IDF, Word2Vec a Doc2Vec bylo 80% dat využito pro učení modelu. Zbylých 20% se využilo pro testování modelu.

Pro klasifikaci pomocí DistilBERT bylo také nutné rozdělit data i do tzv. validační množiny. Osmdesát procent bylo tedy využito pro učení transformeru, 10% jako validační množina a 10% jako testovací množina.

4.3.4 Reprezentace textu

Pro reprezentaci předzpracovaných, popřípadě vyvážených dat bylo v rámci experimentů využito čtyř vektorizačních technik. Těmito technikami jsou TF-IDF, Word2Vec, Doc2Vec a DistilBERT.

Pro vytvoření reprezentace TF-IDF bylo nutné předzpracované věty spojit do jednoho řetězce, kdy oddělovačem byly mezery. Poté byla vytvořena reprezentace, kdy maximální počet rysů byl stanoven na 4000. Tato hodnota udává, kolik nejčastějších rysů korpusu má být zahrnuto při tvorbě reprezentací. Hodnota byla stanovena na základě průběžné optimalizace hyperparametrů.

Pro Word2Vec reprezentaci bylo využito Skip-gram varianty. Vzhledem k specificitě domény dat s nimiž se v rámci tohoto projektu pracovalo, nebylo využito žádného předučeného Word2vec modelu. Model tedy byl naučen na všech slovech z množiny pro učení. Následné vektory vět byly vytvořeny zprůměrováním všech slovník vektorů v dané větě dle doporučení Lau et al. (2016) v jejich publikaci.

U Doc2Vec reprezentace bylo využito varianty DBOW, opět dle doporučení Lau et al. (2016). Před učením modelu bylo nutné věty olabelovat ve speciálním formátu specifikovaném autory Doc2Vec. Stejně jako u Word2Vec, byl Doc2Vec model učen ze začátku na datech z množiny pro učení.

U DistilBERT byly věty spojeny do jednoho řetězce jako u TF-IDF a poté tokenizovány pomocí specializovaného tokenizéru pro tento transformer z knihovny *transformers*. Jako u jiných transformerů je zde omezen počet tokenů u každého vstupního dokumentu. V rámci této práce byla tato maximální hodnota tokenů rovna 256. Jak bylo zmiňováno, u DistilBERT je tokenem wordpiece token, nikoliv slova. V případě, že počet tokenů ve vstupní větě překročil tuto hodnotu, bylo u ní zpracováno jen prvních 256 tokenů. Vzhledem k tomu, že se využívalo pouze vět, nikoliv delších textových dokumentů, byly věty v naprosté většině případů zpracovány celé. Například v případě využití původních nevyvážených dat z části nadpisu a popisu incidentů, překročilo tuto hodnotu 256-ti tokenů pouze 8 vět z 5625.

4.3.5 Klasifikátory

Klasifikátory zmíněné v této sekci byly využity pouze pro vektory vytvořené pomocí TF-IDF, Word2Vec a Doc2Vec. U DistilBERT byla klasifikace provedena klasifikační hlavou tohoto transformeru.

Zvolené klasifikátory byly identické jako u práce Fuchs et al. (2022), popsané v sekci 3.7. Jedná se o následující algoritmy:

- Naive Bayes
- Support Vector Machine
- Random Forest
- Logistická regrese
- K-nearest neighbors

Je nutné dále upřesnit, že u Naive Bayes bylo využito dvou variant tohoto klasifikátoru. Pro TF-IDF byla klasifikace provedena pomocí multinomiální varianty, vzhledem k diskrétní povaze této reprezentace.

Pro Word2Vec a Doc2Vec nebylo možné tuto variantu využít. Odůvodněno je to možnými negativními hodnotami, které tyto modely produkují (na základě nastavení parametru „negative“). Vzhledem k tomu, že Multinomiální Naive Bayes negativní hodnoty neakceptuje, bylo proto pro tyto reprezentace využito Gaussian Naive Bayes.

4.3.6 Evaluace

Výsledky každého experimentu poté bylo nutné nějak kvantifikovat. Byly tedy zvoleny takové evaluační metriky, které poskytují o každém modelu všeobecný pohled na jejich na výkon.

Použitými metrikami jsou accuracy, precision, recall a F1 skóre. Jednotlivé klasifikátory jsou porovnány dle F1 skóre, a to vzhledem k robustnosti této metriky při využití jak nevyvážených i vyvážených datasetů. Pro porovnání je také vzhledem k povaze této práce důležitá metrika recall. Ta vystihuje schopnost klasifikátoru správně predikovat co nejvíce vzorků z pozitivní třídy i za cenu toho, že instance jsou predikovány jako falešná pozitiva.

Pro každý experiment byla rovněž vytvořena matice záměn. Hodnoty pro tyto metriky byly vypočteny funkcí *classification_report* a *conf_matrix* z knihovny *scikit-learn*.

5 Výsledky

V této kapitole budou prezentovány výsledky provedených experimentů. Experimentů bylo provedeno více než 90. Budou zde tedy upřesněny zejména ty experimenty u nichž bylo dosaženo nejlepších výsledků, a to dle metrik F1 a recall. Dále zde bude prezentován dopad využití různých vektorových reprezentací, metod vyvážení dat a klasifikátorů dle zmíněných metrik. Veškeré hyperparametry pro využité vektorizační techniky jsou uvedeny v příloze B. Pro kompletní přehled výsledků všech experimentů byla poskytnuta příloha C.

Je nutné podotknout, že experimenty využívající DistilBERT byly provedeny pouze pro věty z nadpisu a popisu incidentů. Při zahrnutí vět i z komunikační části byla překročena kapacita serveru a experimenty tedy nebylo možné provést.

5.1 Využitý text

V rámci práce byl zkoumán efekt zahrnutí vět z komunikační části incidentů do dat na učení. Oproti případu využití vět jen z nadpisu a popisu incidentů, tím bylo dosaženo až osminásobného zvýšení množství datových vzorků v migrační kategorii a desetinásobného zvýšení v upgrade kategorii. Byl tím tedy masivně zvětšen i dataset pro učení modelů.

I přes to však ve většině případů tato změna nevedla ke zlepšení výsledku klasifikátorů. V případě markantního zlepšení až o více než 15% F1 skóre, se jednalo pouze o experimenty, u nichž bylo využito reprezentace Word2Vec. U všech takový případů bylo toto zlepšení pozorováno pouze pokud při stejných podmínkách a bez využití komunikačních vět klasifikátor dosahoval F1 skóre o hodnotě 50% a méně.

Kombinaci, použitou pro získání nejlepšího výsledku klasifikace při zahrnutí vět z komunikace dle metriky F1, lze vidět v tabulce č. 2.

Tabulka 2: Nejlepší výsledky klasifikace dle metriky F1 při a bez zahrnutí vět z komunikační části

Text	**Reprezentace**	**Vyvážení dat**	**Klasifikátor**	**Accuracy**	**Precision**	**Recall**	**F1**
Komunikace	TF-IDF	Podvzorkování	SVM	73%	74%	72%	73%
Bez komunikace	TF-IDF	Podvzorkování	SVM	72%	70%	76%	73%
Komunikace	TF-IDF	Podvzorkování	Logistická regrese	72%	73%	71%	72%
Bez komunikace	TF-IDF	Podvzorkování	Logistická regrese	73%	71%	77%	74%
Komunikace	TF-IDF	Podvzorkování	Random Forest	73%	75%	71%	72%
Bez komunikace	TF-IDF	Podvzorkování	Random Forest	71%	68%	78%	73%

S ohledem na recall došlo u převážné většiny experimentů při zahrnutí vět z komunikace opět ke zhoršení výsledků. U všech zkoumaných reprezentací bylo dosaženo značného zlepšení pouze v případě, že bylo u původních experimentů (bez vět z komunikace) skóre recall nižší než 50%. V případě zlepšení skóre vyššího než 50% bylo pozorováno maximální zlepšení 6%.

5.2 Vyvážení dat

V práci byl také prozkoumán dopad dvou různých technik vyvážení datasetu, datové augmentace a podvzorkování.

U datové augmentace byl efekt závislý primárně na využité reprezentaci textu. U Doc2Vec a Word2Vec vedla datová augmentace v 75% procentech experimentů ke zhoršení F1 skóre. U zbylých experimentů u nichž byly tyto reprezentace využity bylo maximální zlepšení F1 skóre 5%. Odlišná byla situace u TF-IDF a DistilBERT. V případě TF-IDF bylo u 7 z 10 experimentů pozorováno zlepšení F1 skóre, a to až o 16%. U DistilBERT byl výsledek F1 skóre po využití datové augmentace lepší o 14%.

U podvzorkování bylo zlepšení markantně lepší. U všech provedených experimentů došlo při využití podvzorkování ke zlepšení výsledků klasifikace. U Doc2Vec se např. toto zlepšení u jednotlivých experimentů pohybovalo od 8% až 56% F1 skóre.

Tabulka 3: Nejlepší výsledky klasifikace dle F1 skóre na základě využité metody vyvážení dat

Vyvážení dat	**Reprezentace**	**Text**	**Klasifikátor**	**Accuracy**	**Precision**	**Recall**	**F1**
Žádné	TF-IDF	Komunikace	Logistická regrese	76%	48%	71%	57%
Žádné	TF-IDF	Komunikace	Random Forest	85%	84%	43%	57%
Datová augmentace	DistilBERT	Bez komunikace	Klasifikační hlava	79%	59%	89%	70%
Podvzorkování	TF-IDF	Bez komunikace	Logistická regrese	73%	71%	77%	74%

Stejně jako u F1 skóre, bylo při využití datové augmentace pozorováno ze 75-ti procent zhoršení skóre recall u experimentů využívajících Word2Vec a Doc2Vec, a to v některých případech až o 64%. U TF-IDF a DistilBERT vedlo využití datové augmentace buď k zachování původní hodnoty skóre recall či k jejímu zvýšení (až o 25% u DistilBERT).

Tabulka 4: Nejlepší výsledky klasifikace dle recall skóre na základě využité metody vyvážení dat

Vyvážení dat	**Reprezentace**	**Text**	**Klasifikátor**	**Accuracy**	**Precision**	**F1**	**Recall**
Žádné	TF-IDF	Komunikace	Logistická regrese	76%	48%	57%	71%
Datová augmentace	TF-IDF	Bez komunikace	KNN	38%	25%	39%	91%
Podvzorkování	TF-IDF	Bez komunikace	KNN	62%	58%	70%	89%

5.3 Vektorové reprezentace

Ze všech reprezentací dat využitých v rámci experimentů se dle F1 skóre ukázalo jako nejlepší TF-IDF. Na druhé příčce poté bylo Doc2vec a DistilBERT, na poslední příčce Word2Vec. Rozdíly ovšem nejsou natolik zásadní a mezi nejlepší reprezentací a nejhorší je rozdíl F1 skóre pouze 6%.

Tabulka 5: Nejlepší výsledky klasifikace dle metriky F1 na základě reprezentace dat

Reprezentace	**Text**	**Vyvážení dat**	**Klasifikátor**	**Accuracy**	**Precision**	**Recall**	**F1**
TF-IDF	Bez komunikace	Podvzorkování	Logistická regrese	73%	71%	77%	74%
Doc2Vec	Bez komunikace	Podvzorkování	SVM	68%	66%	75%	70%
Doc2Vec	Bez komunikace	Podvzorkování	Random Forest	69%	68%	72%	70%
DistilBERT	Bez komunikace	Datová augmentace	Klasifikační hlava	79%	59%	89%	70%
Word2Vec	Komunikace	Podvzorkování	Random Forest	69%	71%	65%	68%

Na tabulce č. 6 lze dále vidět matici záměn pro nejlepší klasifikátor využívající TF-IDF reprezentaci.

Tabulka 6: Matice záměn pro nejlepší klasifikátor dle metriky F1 skóre

	Predikovaná pozitiva	**Predikovaná negativa**
Skutečná pozitiva	171	50
Skutečná negativa	70	150

S ohledem na recall a reprezentaci dat dosáhli nejlepších výsledků experimenty využívající DistilBERT a TF-IDF. Rozdíl zde již byl poměrně zásadní, kdy rozdíl mezi nejlepším a nejhorším výsledkem experimentů pro dané reprezentace byl 21%.

Tabulka 7: Nejlepší výsledky klasifikace dle metriky recall na základě reprezentace dat

Reprezentace	**Text**	**Vyvážení dat**	**Klasifikátor**	**Accuracy**	**Precision**	**F1**	**Recall**
TF-IDF	Bez komunikace	Podvzorkování	KNN	62%	58%	70%	89%
DistilBERT	Bez komunikace	Datová augmentace	Klasifikační hlava	79%	59%	70%	89%
Doc2Vec	Bez komunikace	Podvzorkování	SVM	68%	66%	70%	75%
Word2Vec	Komunikace	Podvzorkování	Gaussian NB	69%	71%	65%	68%
Word2Vec	Komunikace	Podvzorkování	Logistická regrese	69%	71%	65%	68%

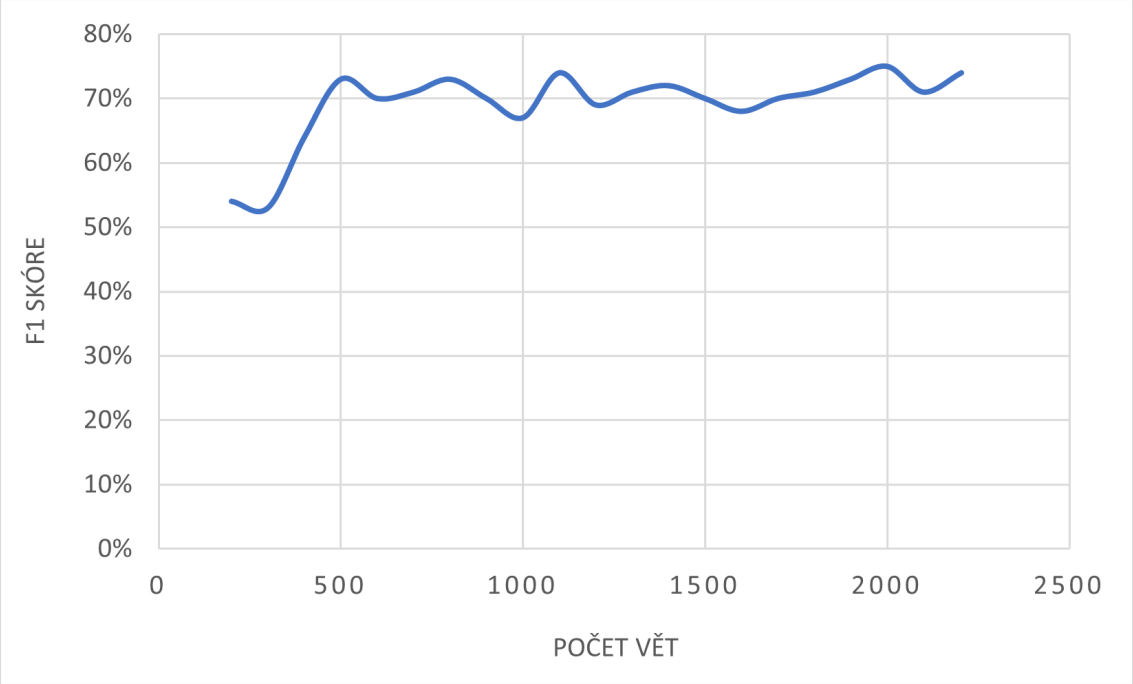
Nejlepších výsledků na základě metriky recall byly reprezentace TF-IDF a DistilBERT. Je nutné podotknout že DistilBERT taktéž dosáhl accuracy skóre 79% oproti 62% u TF-IDF.

Tabulka 8: Matice záměn pro nejlepší klasifikátor dle metriky recall skóre - DistilBERT

	Predikovaná pozitiva	**Predikovaná negativa**
Skutečná pozitiva	154	20
Skutečná negativa	109	319

5.4 Stabilita výsledků

V rámci práce byl taktéž prozkoumán vliv, jaký má počet vzorků datasetu na výsledky klasifikace. V rámci obrázku č. 3 je vykreslena závislost počtu vět na výsledném F1 skóre klasifikátoru TF-IDF (tedy nejlepšího klasifikátoru dle tabulky 5).



Obrázek 3: Stabilita výsledků F1 skóre v závislosti na počtu vět pro nejlepší TF-IDF experiment

6 Diskuze

V rámci této práce byly prozkoumány různé možnosti binární klasifikace incidentů, včetně využití různých možností dat, vyvážení datasetu, reprezentace textu a klasifikačních algoritmů.

V rámci provedených experimentů bylo nejlepšího výsledku F1 skóre o hodnotě 74% dosaženo při kombinaci využití vět z popisu a nadpisu, následného podvzorkování dat, reprezentace pomocí TF-IDF a klasifikace pomocí logistické regrese. V případě, že bude pro výběr klasifikátoru pro nasazení do reálného provozu nejdůležitější hodnota skóre F1 , je tento klasifikátor jednoznačně optimální volbou.

S ohledem na recall, bylo nejlepšího výsledku 89% dosaženo u experimentů využívající reprezentaci TF-IDF a DistilBERT. V případě TF-IDF šlo o stejný systém jako u nejlepšího výsledku na základě skóre F1, bylo ovšem využito klasifikačního algoritmu KNN. V případě DistilBERT šlo o kombinace využití vět z podpisu a nadpisu, datové augmentace a klasifikační hlavy DistilBERT. U obou těchto experimentů bylo taktéž dosaženo F1 skóre o hodnotě 70%. Je však nutné podotknout, že oba klasifikátory mají své výhody a nevýhody. TF-IDF jednu predikci provede výrazně rychleji než-li DistilBERT. DistilBERT naopak v popisovaném experimentu dosáhl výrazně vyššího accuracy o hodnotě 79% oproti 62% u TF-IDF. V případě, že by tedy bylo pro rozhodnutí, jaký klasifikátor nasadit, nejdůležitější metrika recall, bylo by nutné při rozhodnutí učinit kompromis mezi těmito rysy.

Obecně je také vhodné poukázat na fakt, že u experimentů byl překvapivý dopad zahrnutí vět z komunikační části incidentů do dat na učení klasifikátorů. Tento krok obecně nevedl ke zlepšení výsledků. Lze to vysvětlit především výrazně vyšší mírou šumu, jež se ve větách této části incidentů vyskytuje. Věty z nadpisu a popisu naopak většinou přímo objasňují problém, kvůli kterému byl incident vytvořen. V rámci incidentů, s kterými se pracovalo v rámci této práce, šlo tedy o problémy migrace a upgrade. Lze tedy očekávat, že v případě zahrnutí více olabelovaných incidentů do datasetu (obzvlášť z kategorie upgrade) a tedy i vět z částí nadpisu a popisu by vedlo ke zlepšení výsledků klasifikátorů.

Co se týče metod vyvážení dat, nejvyššího zlepšení výsledků klasifikace bylo dosaženo pomocí náhodného podvzorkování, a to u všech experimentů. Naopak datová augmentace pomocí strojového překladu výsledky zlepšovala primárně jen u experimentů, kde bylo využito TF-IDF a DistilBERT. Nelze interpretovat, proč bylo náhodné podvzorkování pro tuto úlohu optimální, oproti zpětnému překladu jako např. v práci od F. Koukala (2022).

Zajímavým poznatkem jsou velmi vyrovnané výsledky reprezentací Doc2Vec a Word2Vec. Dle Lau et al. (2016) je pro reprezentaci vět výrazně vhodnější metoda průměrování Word2Vec vektorů slov ve větách než-li Doc2Vec. Tato hypotéza nebyla v rámci této práce potvrzena a Doc2Vec metodu Word2Vec předčil.

V práci F. Koukala (2022) se ukázala jako nejlepší vektorizační metoda BERT v kombinaci s dodatečným klasifikačním algoritmem. Tento způsob nebyl v rámci této práce prozkoumán. Lze diskutovat, že uplatnění tohoto přístupu by mohlo

výsledky DistilBERT zlepšit.

Zvolená metodika a výsledky experimentů byly značně limitovány kapacitami serveru využitého pro provedení implementace. Nebylo např. možné provést učení transformeru na větách zahrnující i komunikační část incidentů, protože při procesu učení došlo mnohokrát k selhání prostředí Jupyter Lab. Učení modelů bylo obecně zdlouhavější než bylo nutné, což značně limitovalo rozsah provedených experimentů. Pro budoucí projekty by tedy bylo doporučeno využít více výpočetních zdrojů.

Jak bylo zmíněno, v rámci této práce byly prozkoumány možnosti binární klasifikace vět v prostředí SAP. Tato práce byla vyvinuta jako rozšíření pro současně vyvíjený klasifikátor, který klasifikaci provádí na základě kategorie, k níž patří věty incidentů. Vzhledem k tomu, že nebyla tato práce dokončena, nebylo možné provést evaluaci na finálním systému zahrnujícím oba klasifikátory. Reálný dopad této práce tedy nebyl prozkoumán. Až po nasazení obou klasifikátorů bude možné prozkoumat hodnoty vnitřních evaluačních metrik pro klasifikaci incidentů na základě vět. Poté bude také možné získat výsledky na základě vnějších evaluačních metrik.

7 Závěr

Cílem této práce bylo vybudování binárního klasifikátoru zákaznických incidentů v prostředí SAP. V první řadě byl představen kontext, v jakém projekt vznikl. Byl popsán produkt S/4HANA společnosti SAP, včetně klíčové situace migrace a upgrade. Dále byla představena oblast NLP a strojového učení. Poté bylo zaměřením samotná klasifikace, včetně předzpracování dat, možných metod reprezentace textu, klasifikačních algoritmů a evaluace. V poslední řadě byly probrány již existující práce zabývající se obdobným tématem jako je tato práce. Získané znalosti byly uplatněny pro implementaci více než 90 experimentů za účelem nalezení optimálního klasifikačního systému dle cíle práce.

V závěru může být řečeno, že v rámci provedených experimentů bylo dle metrik F1 a recall dosaženo nejlepších výsledků při využití vektorizačních technik DistilBERT a TF-IDF. V některých situacích tedy může TF-IDF stále poskytnout srovnatelné či dokonce lepší výsledky jako zmíněné mnohem modernější vektorizační techniky. Výsledky také indikují význam vyvažovacích technik, které mohou výrazně zlepšovat výsledky klasifikačních systémů. Byla také vyvozena řada znalostí, jež lze dále uplatnit pro klasifikaci incidentů v prostředí SAP.

Pro lepší pochopení implikací této práce či zlepšení výsledků systému, by bylo doporučeno prozkoumat způsob provedení některý fází experimentů, jako např. předzpracování. Ta byla založena především na dříve vyvíjených klasifikačních systémem v rámci SAP. Nelze však říct, že zvolený přístup předzpracování byl tím optimálním. V rámci práce taktéž mohl být systematicky provedena optimalizace hyperparametrů, např. pomocí techniky *GridSearchCV*. To by opět mohlo zlepšit výsledky pro experimenty využívající různé textové reprezentace. Lze také doporučit zvětšení

V závěru lze konstatovat, že cíl práce byl, dle dosažených výsledků experimentů, úspěšně splněn.

8 Literatura

ADEL, H. ET AL. *Improving crisis events detection using distilbert with hunger games search algorithm* [online]. Mathematics, 2022, [cit. 2023-03-13]. Dostupné z: https://www.mdpi.com/2227-7390/10/3/447.

BAUMGARTL, A. ET AL. *SAP S/4HANA: An Introduction* Boston: Rheinwerk Publishing, 2016. 447 s. ISBN 978-1-493-21401-3.

BENGFORT, B. ET AL. *Applied Text Analysis with Python: Enabling Language-Aware Data Products with Machine Learning* Sebastopol: O'Reilly, 2018. 332 s. ISBN 1-491-96299-2.

BORG, A. ET AL. *E-mail classification with machine learning and word embeddings for improved customer support* [online]. Neural Comput Applic 33, 2021. [cit. 2023-03-06]. Dostupné z: https://doi.org/10.1007/s00521-020-05058-4.

BROWNLEE, J. *Difference Between Algorithm and Model in Machine Learning* [online]. machinelearningmastery.com, 2020. [cit. 2023-03-06]. Dostupné z: https://machinelearningmastery.com/difference-between-algorithm-and-model-in-machine-learning/?___cf_chl_tk=wYeZqESWmbWd905ltwK_kpxi3lDrV1SNkwzOXRr5WN8--1678300244-0-gaNycGzNCvs.

BÜYÜKÖZ, B. ET AL. *Analyzing ELMo and DistilBERT on Socio-political News Classification* [online]. AESPEN, 2020. [cit. 2023-03-13]. Dostupné z: https://aclanthology.org/2020.aespen-1.4.pdf.

CHOPRA, A. ET AL. *Natural language processing* [online]. 3rd International Conference on Computational Systems and Information Technology for Sustainable Solutions 8th International Multitopic Conference, 2004. Proceedings of INMIC 2004, 2004. [cit. 2023-03-06]. Dostupné z: https://citeseerx.ist.psu.edu/document?repid=rep1type=pdfdoi=eeace1d14e266a5cd44fe781a874c662928602fd.

DEVLIN, J. ET AL. *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding* [online]. CoRR, 2018. [cit. 2023-03-11]. Dostupné z: http://arxiv.org/abs/1810.04805.

PINAR, E. *Naive Bayes Classifiers for Text Classification* [online]. towardsdatascience.com, 2023. [cit. 2023-03-12]. Dostupné z: https://towardsdatascience.com/naive-bayes-classifiers-for-text-classification--be0d133d35ba.

FUCHS, S. ET AL. *E-mail classification with machine learning and word embeddings for improved customer support* [online]. Proceedings of the 55th Hawaii International Conference on System Sciences, 2022. [cit. 2023-03-06].

Dostupné z: http://hdl.handle.net/10125/79570.

Fuchs, S. *Towards an Automated SAP Service Desk -Design and Implementation of a Prototype Machine Learning Classifier for Support Tickets on a Small Data Set* [online]. ResearchGate, 2022. [cit. 2023-03-06]. Dostupné z: https://www.researchgate.net/publication/363660538_Towards_an_Automated_SAP_Service_Desk_Design_and_Implementation_of_a_Prototype _Machine_Learning_Classifier_for_Support_Tickets_on_a_Small_Data_Set.

Goldberg, Y. *Neural Network Methods for Natural Language Processing* San Rafael: Morgan Claypool, 2017. 311 s. ISBN 978-1-627-05298-6.

Gupta, M. et al. *Reducing user input requests to improve IT support ticket resolution process* [online]. Empirical Software Engineering, 2018, 1664-1703. [cit. 2023-03-06]. Dostupné z: https://www.win.tue.nl/ aserebre/EMSE2017Monika.pdf.

Joyce, J. *Bayes' Theorem* [online]. https://plato.stanford.edu/, 2023. [cit. 2023-03-12]. Dostupné z: https://plato.stanford.edu/entries/bayes-theorem/.

Koukal, F. *Automatická kategorizace zákaznických požadavků* Diplomová práce. Brno: Mendelova univerzita v Brně, 2022. .

Kotsiantis, S. et al. *Handling imbalanced datasets: A review* [online]. GESTS International Transactions on Computer Science and Engineering, 2006. [cit. 2023-03-06]. Dostupné z: https://www.semanticscholar.org/paper/Handling-imbalanced-datasets:-A-review-Kotsiantis-Kanellopoulos/95dfdc02010b9c390878729f459893c2a5c0898f.

Kumara, B. A. et al. *Improved email classification through enhanced data preprocessing approach* [online]. Spat. Inf. Res. 29, 2021, 247–255. [cit. 2023-03-06]. Dostupné z: https://doi.org/10.1007/s41324-020-00378-y.

Lai, S. et al. *Recurrent Convolutional Neural Networks for Text Classification* [online]. AAAI Press, 2015, 2267–2273. [cit. 2023-03-06]. Dostupné z: https://ojs.aaai.org/index.php/AAAI/article/view/9513.

Lau, J. H. et al. *An Empirical Evaluation of doc2vec with Practical Insights into Document Embedding Generation* [online]. CoRR, 2016. [cit. 2023-03-06]. Dostupné z: http://arxiv.org/abs/1607.05368.

Lauriola, I. et al. *An introduction to Deep Learning in Natural Language Processing: Models, techniques, and tools* [online]. 2022. [cit. 2023-03-06]. Dostupné z: https://doi.org/10.1016/j.neucom.2021.05.103.

Minaee, S. et al. *Deep Learning Based Text Classification: A Comprehensive Review* [online]. CoRR, 2020. [cit. 2023-03-06]. Dostupné z:

https://arxiv.org/abs/2004.03705.

Mikolov, T. et al *Efficient Estimation of Word Representations in Vector Space* [online]. arXiv, 2013. [cit. 2023-03-10]. Dostupné z: https://arxiv.org/abs/1301.3781.

Mikolov, T. et al *Distributed Representations of Sentences and Documents* [online]. arXiv, 2014. [cit. 2023-03-06]. Dostupné z: https://arxiv.org/abs/1405.4053.

Murphy, K. P. *Machine learning : a probabilistic perspective* Massachusetts: Massachusetts Institute of Technology, 2012. 1098 s. ISBN 978-0-262-01802-9.

Opuchlich, P. *Text Classification of Support tiket Data of SAP* [online]. ResearchGate, 2019. [cit. 2023-03-06]. Dostupné z: https://www.researchgate.net/publication/340492353_Text_Classification_of_Support_tiket_Data_of_SAP.

Pagliardini, M. et al *Unsupervised Learning of Sentence Embeddings Using Compositional n-Gram Features* [online]. Association for Computational Linguistics, 2018. [cit. 2023-03-06]. Dostupné z: https://arxiv.org/pdf/1703.02507.pdf.

Paramesh, S. P. et al. *Classifying the Unstructured IT Service Desk Tickets Using Ensemble of Classifiers* [online]. 3rd International Conference on Computational Systems and Information Technology for Sustainable Solutions (CSITSS), 2018, 221-227. [cit. 2023-03-06]. Dostupné z: https://arxiv.org/abs/2103.15822v1.

Paramesh, S. P. et al. *Automated IT Service Desk Systems Using Machine Learning Techniques* [online]. Springer, 2019. [cit. 2023-03-06]. Dostupné z: https://doi.org/10.1007/978-981-13-2514-4_28.

Peters, M. E. et al. *Deep contextualized word representations* [online]. CoRR, 2018. [cit. 2023-03-11]. Dostupné z: http://arxiv.org/abs/1802.05365.

Prahbu, S. et al. *Multi-class Text Classification using BERT-based Active Learning* [online]. CoRR, 2021. [cit. 2023-03-06]. Dostupné z: https://arxiv.org/abs/2104.14289.

Qaiser, S. et al. *Deep contextualized word representations* [online]. International Journal of Computer Applications, 2018. [cit. 2023-03-12]. Dostupné z: https://www.researchgate.net/publication/326425709_Text_Mining_Use_of_TF-IDF_to_Examine_the_Relevance_of_Words_to_Documents.

Raschka, S. *Python Machine Learning* Birmingham: Packt Publishing, 2016. 454 s. ISBN 978-1-78355-513-0.

Sanh, V. et al *DistilBERT, a distilled version of BERT: smaller, faster, cheaper*

and lighter [online]. arXiv, 2019. [cit. 2023-03-06]. Dostupné z: https://arxiv.org/abs/1910.01108.

Sanh, V. *Smaller, faster, cheaper, lighter: Introducing DistilBERT, a distilled version of BERT* [online]. https://medium.com/huggingface/distilbert-8cf3380435b5, 2019. [cit. 2023-03-13]. Dostupné z: https://medium.com/huggingface/distilbert-8cf3380435b5.

SAP *Co je to strojové učení?* [online]. SAP, 2023. [cit. 2023-03-06]. Dostupné z: https://www.sap.com/cz/insights/what-is-machine-learning.html.

SAP *What is ERP - Enterprise resource planning definition* [online]. SAP, 2023. [cit. 2023-03-06]. Dostupné z: https://www.sap.com/insights/what-is-erp.html.

SAP *Upgrading SAP S/4HANA - How, Why, and Best Practices* [online]. SAP, 2023. [cit. 2023-03-06]. Dostupné z: https://www.sap.com/documents/2020/06/94ca0995-9d7d-0010-87a3--c30de2ffd8ff.html.

Sarkar, D. *Text Analytics with Python: A Practical Real-World Approach to Gaining Actionable* Bangalore: Insights from Your Data, 2016. 397 s. ISBN 978-1-4842-2388-8.

Schmidthals, A. *Maintenance Timelines for SAP ERP 6.0* [online]. SAP, 2022. [cit. 2023-03-06]. Dostupné z: https://www.erpresearch.com/en-us/blog/sap-ecc-6.0-end-of-support.

Staykovski, T. et al *Dense vs. Sparse Representations for News Stream Clustering* [online]. CEUR-WS.org, 2019. [cit. 2023-03-11]. Dostupné z: https://ceur-ws.org/Vol-2342/paper6.pdf.

Tan, A. *SAP to invest* $S250 min Singapore innovation lab [online]. SAP, 2022. [cit. 2023-03-08]. Dostupn z : https://www.computerweekly.com/news/252514991/SAP-to-invest-S250m-in-Singapore-innovation-lab.$

Vajalla, S. et al. *Practical Natural Language Processing* Sebastopol: O'Reilly, 2020. 455 s. ISBN 978-1-492-05405-4.

Zheng, A. et al. *Feature Engineering for Machine Learning: Principles and Techniques for Data Scientists* Sebastopol: O'Reilly, 2018. 218 s. ISBN 978-1-491-95324-2.

Přílohy

A SAP incident

InfoDoc 35118 / 2019 / Issue in Asset balances report S_ALR_87010124 / SAP Delivered Support

Communication

Info to SAP 29.01.2019 15:12:00 ***
Hello *
Your answer is not satisfactory, please test the same report in 1610 FP00 or any other ERP system as well.
We never faced this issue in ERP or S/4H 1610 FP00.
We are facing this issue after upgrade to SP04. You can see the last screen shot of the attached document, which is from our FP00 release system (C12 sandbox), where there are no Zero valued assets displayed.
We are expecting a fix from you as soon as possible.
Thanks

Reply 29.01.2019 13:34:04 I312875
Dear *
We have been checking in our internal systems and the behavior you report is the correct one.
The assets that do not have any acquisition done are displayed in this report also.
That is the standard behavior.
The logic of this report is to display all existing assets, no matter what values have.
Best regards,
*
SAP Product Support

Info to SAP 28.01.2019 16:35:59 ***
Hello,
May I know the updates on this issue?
Thanks

Problem Description 18.01.2019 18:57:07 ***
Hello SAP,
We recently upgraded our S/4H 1610 system from FP00 to SP04. After go-live we are facing issue in Asset balances report S_ALR_87010124. This report is showing all deactivated assets with zero balance as well. Before we did not face this issue in FP00.
Please find attached document (Issue in asset balances report.docx) for more details. It is a critical report for us and I request you to fix this issue as soon as possible.
Thanks

Details

Incident ID:	123456789 2019	EN
Description:	Issue in Asset balances report S_ALR_87010124	
Component:	FI-AA-IS	Information System
Status/Priority:	Closed	Medium
Quarantine:	Early Adopter Care:	
Classified:		Esc:
Error Category 1:		
Error Category 2:		
Internal Error Category:		

Customer Data

Customer:	Sample Company	111111
Contract Type:	ES	Ltd. Support
Partner Type:		CA

Partner and Organization

Last changed by:	XXXXXX	29.03.2023 11:55
Processor:	XXXXXX	29.03.2023 11:55
Processing Org:		DS IMS
Support Partner:		
Service Partner:		

Dates

Last Update:	13.05.2019 23:06:00
Created:	13.05.2019 23:06:00
Incident Created:	18.01.2019 19:57:07
Incident Confirmed:	12.02.2019 18:05:07

Environment

System ID / Role:	B12	DEMO / OnPrem
Product & Version:	SAP S/4HANA 1610	
Installation No.:	11111111	EWA
SAP Release:	751	
Router Maintained:		
Operating System:	LINUX_X86_64	
Database / Release:	HDB / 1.00.122.17.1526	
Data Protection / Security:		

B Hyperparametry modelů

B.1 Doc2vec - odstranění šumu

- dm - 0
- dm_mean=1
- vector_size - 1000
- window - 4
- negative - 5
- min_count - 2
- workers - 0
- alpha - 0.1
- seed - 23
- max_epochs - 50

B.2 Doc2vec - klasifikace

- dm - 0
- dm_mean=1
- vector_size - 100
- window - 5
- negative - 15
- min_count - 2
- workers - 4
- min_alpha - 0.0001
- alpha - 0.025
- seed - 23
- max_epochs - 200

B.3 Word2Vec

- sg - 1
- vector_size - 100

- window - 3
- negative - 5
- min_count - 4
- workers - 4
- hs - 1
- min_alpha - 0.0001
- alpha - 0.025
- seed - 23
- max_epochs - 20

B.4 DistilBERT

- max_length - 256
- batch_size - 8
- epochs - 3
- learning_rate - 2e-05
- truncation - True
- padding - True

B.5 TF-IDF

- max_features - 4000
- sublinear_tf - True
- smooth_idf - True

C Elektronická příloha

Obsahem elektronické přílohy je kód v HTML podobě využitý pro provedení všech experimentů práce. V příloze lze najít následující složky:

- **DistilBERT** - Experimenty zahrnující využití transformeru DistilBERT
- **tf-idf** - Experimenty zahrnující využití reprezentace TF-IDF
- **Doc2Vec** - Experimenty zahrnující využití reprezentace Doc2Vec
- **Word2Vec_avg** - Experimenty zahrnující využití reprezentace Word2Vec

Dále jsou k dispozici tři soubory zabývající se předzpracováním dat a datovou augmentací:

- **inc_preprocessing** - Kód pro předzpracování dat, využitý pro experimenty využívající TF-IDF, Word2Vec a Doc2Vec.
- **preprocess_last_mod** - Doplňkový kód pro předzpracování dat. Nejde o vlastní práci autora a tento kód je uplatněn ze zmiňovaného současně vyvíjeného klasifikačního systému.
- **data_augment** - Kód pro vykonání datové augmentace pro předzpracovaný kód

Vzhledem k citlivé povaze dat, kterých se v rámci této práce využívalo, nebyly přiloženy jakékoliv soubory obsahující data incidentů či kód zabývající se sběrem dat.